정답 보고서 (상세판 v3) · 노후 신탁 프로젝트 · 2026.11

지금은 괜찮은 50~69세 중 앞으로 반복해서 빈곤선 아래로 떨어질 사람을 머신러닝이 먼저 찾는다

6개 국가 패널 · 사람×차수 단위 · 가처분소득 · “3번 중 2번 이상 부족” 반복 관측 정답 · 미래 차수 봉인 시험

> “가처분소득이 있는 3개 국가 패널에서 같은 정의로, 은퇴 전후의 지속적 소득 하락을 지금 소득만 볼 때보다 일관되게 더 잘 찾는다” — **지지됨**
>
> 결합 AUC 향상(최종 모델 − 지금 소득) +0.064 (95% CI +0.053 ~ +0.075), p <0.001. 사전 지정 LightGBM 단독 +0.060 [+0.045, +0.075]. 재현(노동패널)·이식(의료·고령화)에서도 같은 방향

0.870
복지패널 시험 AUC (가처분소득이 가장 정교한 조사)
지금 소득 하나: 0.811

+0.064
3개 패널 결합 AUC 향상
모든 패널·모든 집단에서 양수

111명 vs 84명
같은 377명 상담 시 실제 하락자
(ML vs 기존 충족률 계산, 국민노후)

표본
학습 103,864행 · 시험 31,544행
(7개 과제, 사람×차수)

ML이 맞다
질문 12개 고정: ML 선택 0.773 > 전문가 0.757 · 무작위 0.759

비즈니스
같은 상담 인력으로 하락자 32% 더 발견 → 진단·경보·브릿지 신탁

차별성
기존 소득·충족률 기준이 못 보는 “아직 괜찮은 사람”을 먼저

원자료는 각 패널 이용약관상 재배포 금지 – 이 문서에는 집계 결과만 담았다. 모든 AUC는 처음부터 떼어 둔 최근 차수 시험셋에서 한 번만 채점했다.

0 한눈에 보기

결론

은퇴 전후(50~69세)에 오는 지속적인 소득 하락은 지금 소득만으로는 잘 안 보인다. 가처분소득 3개 패널에서 지금 소득 하나의 시험 AUC는 평균 0.734이다. 소득 이력, 취업 변화, 정년·연금 개시까지의 거리, 가구 구조, 자산·연금·건강을 함께 학습한 최종 모델은 0.803이다. 복지패널은 0.870까지 올라간다. 결합 향상은 +0.064로 모든 패널에서 양수였다. 노동패널(재현)과 의료·고령화패널(이식)에서도 같은 방향이었다. 사람이 만든 계산식인 국민노후패널의 충족률보다 같은 상담 인원으로 32% 더 많은 하락자를 찾는다.

과제별 시험 성적

과제	시험 행	하락률	지금 소득	계산기형	로지스틱	LightGBM	최종 모델	향상
복지(가처분)	**4,984**	**6.0%**	**0.811**	**0.835**	**0.874**	**0.861**	**0.870**	**+0.058**
재정(가처분)	3,699	10.3%	0.724	0.748	0.786	0.791	**0.794**	**+0.070**
국민노후(가처분)	1,752	9.9%	0.668	0.698	0.732	0.742	**0.746**	**+0.078**
국민노후(필요생활비)	1,887	10.4%	0.706	0.723	0.780	0.787	**0.796**	**+0.089**
노동(경상·재현)	10,496	9.9%	0.751	0.781	0.804	0.802	**0.807**	**+0.056**
의료(경상·이식)	5,034	8.4%	0.740	0.754	0.773	0.767	**0.773**	**+0.032**
고령화(경상·이식)	3,692	12.8%	0.757	0.763	0.761	0.776	**0.774**	**+0.017**

최종 모델 = LightGBM과 로지스틱 회귀의 위험 순위 평균. 판정용 사전 지정 모델은 LightGBM 단독이며, 두 결과를 모두 보고한다.

먼저 알아둘 용어

AUC – 실제로 떨어진 사람 1명과 떨어지지 않은 사람 1명을 무작위로 뽑았을 때, 모델이 떨어진 사람에게 더 높은 위험 점수를 줄 확률. 0.5는 동전 던지기, 1.0은 완벽.
예: AUC 0.87 = 100쌍 중 87쌍에서 실제 하락자를 더 위험하다고 맞힘.

가처분소득 – 경상소득에서 세금·사회보험료·이자 같은 비소비지출을 뺀, 가구가 실제로 쓸 수 있는 돈.
예: 연 경상소득 4,000만원에서 세금·보험료 600만원을 내면 가처분소득 3,400만원.

균등화 – 가구소득을 √가구원수로 나눠 1인 기준 생활 수준으로 맞추는 것.
예: 4인 가구 6,000만원 → 6,000/√4 = 1인 기준 3,000만원.

빈곤선 – 전국 사람들의 균등화 가처분소득을 줄 세웠을 때 가운데 값(중위값)의 50%. OECD 상대빈곤 기준.
예: 2023년 약 1,956만원(경상)·1,779만원(가처분, 2023년 가격).

사람×차수 – 한 사람의 매 조사 시점을 한 행으로 만든 단위. “t 시점 상태 → 그 뒤 몇 년의 결과”가 한 행이 된다.
예: 2015·2017·2019년에 조사된 사람은 3행.

0-1 받은 피드백과 예상 질문에 대한 답

한 줄 답 → 근거 숫자 → 자세한 장 순서로 정리했다.

질문	한 줄 답	근거 (모두 봉인 시험)	장
① 국민연금 조회·은행 노후 계산기와 뭐가 다르냐 받은 피드백	계산을 대체하지 않는다. 계산이 "괜찮다"고 한 사람 중 실제로 반복 부족해질 사람을 찾는 **2차 검진**이다.	계산상 괜찮은 사람 안에서 충족률 AUC 0.687~0.734 vs ML 0.710~0.791. 같은 인원(상위 10%) 상담 시 부족자 11%~27% 더 발견. ML 상위 10%의 실제 반복 부족률 14%~37% vs 나머지 70% 3%~4%	15-1
② 핵심 모델(M1)이 기존 서비스와 비슷하다 받은 피드백	M1은 "지금 부족한가"에 가까운 질문이라 기존 계산과 같아 보였다. 이번 모델은 질문을 "지금은 괜찮은데 앞으로 반복 부족"으로 바꿨다.	같은 데이터에서 상태형 정답은 지금 소득만으로 0.888(ML 이득 +0.019), 이번 정답은 0.734(이득 +0.069). 기존 서비스가 이미 아는 사람이 아니라 못 보는 사람을 맞힌다	3, 15-1
③ 왜 ML이어야 하냐 받은 피드백	사람이 정한 계산식이 아니라 **실제 결과로 학습한 가중치·질문·패턴**이 미래 사람에게서 더 잘 맞았다. 일 전환 문제에서는 부스팅이 로지스틱보다도 유의하게 높다.	계산기형 대비: 소득 하락 +0.038, 그만둠 +0.104, 재취업 +0.142(6/6 조사 통과). 로지스틱 대비 LightGBM: 그만둠 +0.016 [+0.005, +0.027], 재취업 +0.016. 질문 12개 고정 시 ML 선택 > 전문가 양식. 개인별 이유·적응형 질문·판단 보류는 ML만 할 수 있는 기능	6, 8, 15-2, 16
④ 표본이 작다 예상 질문	사람×차수 단위로 학습 103,864행·시험 31,544행. 신뢰구간도 사람 단위로 보수적으로 구했다.	판정 3개 패널 결합 표준오차 0.006 → +0.03 차이 검출 가능. 사람 단위 부트스트랩으로도 결론 유지(+0.064, 하한 +0.052)	4, 7
⑤ AUC가 낮다 예상 질문	0.9는 지금 소득이 다 맞히는 쉬운 정답에서만 나온다. 이 문제의 천장은 약 0.80이고, 가처분소득이 정교한 복지패널은 0.870.	AUC 대신 현장 지표: 같은 상담 인원으로 하락자 +18~32%(과제별). 15종 모델이 모두 같은 높이에서 멈춤 = 데이터의 신호를 다 뽑았다는 신호	3, 6, 13
⑦ 서비스가 복잡하다 예상 질문	첫 제품은 하나다: 기관이 명단을 올리면 "우선 상담 순위 · 이유 3가지 · 판단 보류"를 돌려준다. 개인 진단은 같은 엔진의 화면이다.	기술 설계도 한 장으로 정리. 개인 진단은 ML이 고른 12문항(전체 입력과 비슷한 성능, 8장). 사람마다 질문을 바꾸는 적응형 질문은 큰 패널에서만 통해 다음 단계로 둠(16-2)	13-1, 16-2

1 사용한 데이터와 관계

6개 국가 패널은 모두 같은 사람을 여러 해 추적하는 조사다. 하지만 주관 기관·주기·소득 측정 방식이 다르다. 이 차이가 각 패널의 역할을 정한다.

패널(주관)	원자료	주기 · 사용 차수	사람×차수(50~69세, 소득 관측)	가처분소득	이번 역할
한국복지패널 KOWEPS 보건사회연구원·서울대	가구원 통합 CSV 20개 (2005~2024 소득연도) + 코드북	매년 · 1~20차	48,874	**있음** h_din (기관 산출)	**정답 · 판정**
재정패널 NaSTaB 조세재정연구원	차수별 가구·가구원 Stata 17+17개	매년 · 1~17차	29,918	**있음** 경상 − 비소비지출	**정답 · 판정**
국민노후보장패널 KReIS 국민연금연구원	개인·가구 장기 CSV + 코드북 v10.3	격년 · 1~10차 (2005~2023)	13,919	**있음** hdin 처분가능소득	**정답 · 판정** + 필요 생활비 (계산) 검증
한국노동패널 KLIPS 한국노동연구원	차수별 가구·개인 Stata 27+27개	매년 · 8~27차 사용	63,859	없음 (경상 항목 합산)	**재현** – 가장 큰 표본
한국의료패널 KHP 보건사회연구원·건보공단	연도별 Stata (1기 2008~18, 2기 2019~24)	매년 · 1·2기 분리	37,828	없음 (총소득)	**이식 검증**
고령화연구패널 KLoSA 고용정보원	종단 요약 Excel 9개(Lt) + 원자료	격년 · 1~9차 (2006~2022)	18,388	없음 (총소득)	**이식 검증**

1-1. 데이터 관계도 – 원자료에서 판정까지

① 원자료 6종
CSV · Stata · Excel
가구 파일 + 개인 파일
차수별 ID 체계 상이

→

② 공통 스키마
패널, 사람ID, 가구ID, 조사연도, 소득연도, 나이, 성별, 학력, 배우자, 가구원 수, 가구 경상·가처분소득, 취업 + 조사별 추가 변수(x_)

→

③ 소득 척도 통일
만원 · 2023년 가격 (CPI)
균등화(÷√가구원수)
빈곤선 대비 비율

→

④ 사람×차수 연결
같은 사람의 t−4, t−2, t−1 (이력)과 t+1~t+4 (결과)를 한 행에

→

⑤ 정답 · 봉인
3번 중 2번 이상 부족
최근 2개 차수 = 시험

판정 (가처분소득)
복지 · 재정 · 국민노후
같은 정의로 각자 학습 → 결합
메타분석으로 주장 판정

현장 기준 검증
국민노후 전용
필요 최소생활비 · 충족률 계산
· 본인 걱정과 직접 비교

재현
노동패널(최대 표본)
가처분소득이 없어 경상소득
기준으로 같은 방향인지 확인

이식
의료 · 고령화
다른 패널에서 학습한 모델을
옮겼을 때 순위·확률이
유지되는지

역할 분담은 이전 실험 노트의 원칙("가처분소득이 없는 조사는 정답용으로 쓰지 않고 이식·보정 확인용으로")을 따른 것이다.

1-2. 패널별 변수 매핑 (원자료 변수명 → 공통 스키마)

공통 항목	복지	재정	국민노후	노동	의료	고령화
사람 ID / 가구 ID	h_pid / h_id	pid / hid(차수별)	pid / hid	pid / hhid(차수별)	PIDWON·pidwon (1·2기 별도)	pid / HHID
나이	연도 − h_g4(출생)	소득연도 − pw_byr	age	p0107 만나이	연도 − C4_0 / birth_y	A002_age
가구 경상소득	h_cin	h_inc_a	hd002b(천원)	근로+금융+임대 +사회보험+이전 합	TOTAL / h_inc_tot	hhinc
가처분소득	h_din	inc_a − exp_b	hdin(천원)	–	–	–
가구원 수	h01_1	w_fnum	num	h0150	B1 / fam_n	hhsize
취업	h_eco4 1~7	p_aa001 (소득활동)	pa001=1 취업자	p0211 취업형태	C24 / eco1	present_labor
종사상지위·직종	h_eco4, h_eco9	pw_jpo, pw_job	pa003·pa005, pa007	p0314, p0350~52	C33 / eco2	status, job
공적연금	p01_1 수급, h_soc_2 가입형태	p_bc001 가입, inc_ba1 금액	pd001 1가입·2수급	p2101 가입	C15	national+particular
건강	h_med2, h_g9_1 만성	–	pk010, pk011	p6101	cd, hs_srh	C001, chronic_sum, adl
자산·부채	h10 금융·부동산, h09 부채	fa 금융, fc001 부채	he001 부동산, he003 금융, he004 부채	h2562~ 금융, h2602~ 부채, 시가	prop, debt(2기)	hhnetassets, financialasset
현장 기준 (전용)	–	–	pc003/004 필요 최소생활비, pc019·pc010 준비·충분성	–	–	–

1-3. 원자료를 열면서 만난 문제와 처리

- **국민노후패널**: 처음엔 코드북 없이 값 분포로 역추정했고(pa001 1=취업, 금액 천원 등), 받은 코드북 v10.3으로 모두 맞음을 확인했다. 코드북을 보고 가구소득을 hd001b(총소득, 비경상 포함)에서 **hd002b(경상)**로 바꿨다. kreispl13은 kreispl05와 같은 사람·같은 값이라 중복 제거. 2023 신규표본(kreishl23)은 미래 결과가 없어 제외. 처분가능소득(hdin)은 2007년 차수부터 있다.
- **의료패널**: 1기(2008~2018)와 2기(2019~2024)의 개인 ID가 이어지지 않아 따로 추적했다. 기간을 넘는 정답은 만들지 않았다. 1기 파일은 cp949 라벨·대소문자 혼재를 정리했다.
- **노동패널**: 가구 경상소득이 항목별로만 있어 근로·금융·임대·사회보험·이전소득을 합산했다(매매차익·퇴직금·상속 제외). 배우자 유무는 같은 가구·같은 차수에 가구주(10)와 배우자(20)가 함께 있으면 기혼으로 판단했다.
- **고령화패널**: Excel 파일의 비표준 속성(synchVertical) 때문에 openpyxl이 읽지 못해 패치 후 변환했다. 종단 요약 파일(Lt)의 생성 변수(hhinc, hhnetassets, chronic_sum 등)를 사용했다.
- **재정패널**: 가처분소득 생성 변수가 없어 가구 경상소득(inc_a)에서 비소비지출(exp_b)을 뺐다.
- **단위 점검**: 6개 패널의 소득/빈곤선 중위값이 1.74~2.06배로 비슷하다. 단위나 개념이 틀렸다면 여러 배 벌어졌을 것이다.

2 전처리 상세

1. **대상 연령과 기간** – 패널별 변환 단계에서 45~80세를 남겨 이력(t−4)과 결과(t+4)를 붙일 여유를 둔다. 분석 행은 t 시점 50~69세. 소득연도 2004~2024(CPI 범위).
2. **금액 통일** – 모두 연 만원. 국민노후패널은 천원÷10. 소득 기준연도(대부분 “작년 한 해”)의 CPI로 2023년 가격 환산.
3. **균등화 소득비** – r = (가구소득 ÷ √가구원수, 2023년 가격) ÷ 그 해 빈곤선. 가구원 수가 빠진 차수는 같은 사람의 앞뒤 차수로 채우고, 그래도 없으면 2명.
4. **빈곤선 두 종류** – 복지패널 전 연령, 개인 횡단 가중치로 연도별 가중 중위값의 50%를 구한다. **가처분 빈곤선**(판정 3개 패널)과 **경상 빈곤선**(노동·의료·고령화). 국민노후패널은 추가로 연도·가구유형(부부/개인)별 **필요 최소 노후생활비 응답 중위값**을 기준선으로 쓴다.
5. **사람×차수 연결** – (패널, 사람, 조사연도) 키로 같은 사람의 t−4, t−2, t−1과 t+1, t+2, t+3, t+4를 붙인다. 매년 조사는 한 해 단위, 격년 조사는 2년 단위로 붙는다.
6. **이력 변수** – 2·4년 소득 변화(로그), 최근 4년 최저 소득비, 소득 변동성(t, t−2, t−4의 표준편차), 과거 빈곤 경험, 2년 내 실직, 2년간 가구원 변화, 60세까지 거리, 출생연도별 국민연금 개시연령(60~65세)까지 거리.
7. **조사별 추가 변수** – 자산·부채는 원금액 대신 **소득 대비 배수**와 로그로(소득 수준과 중복 제거). 비어 있는 비율이 80% 넘거나 값이 하나뿐인 변수는 그 패널에서 제외.
8. **결측·극단값** – 부스팅은 결측을 그대로 학습한다(결측 자체가 정보). 선형·거리 모델은 중앙값 대체 + 결측 표시. 극단값은 **학습 구간의** 0.5/99.5% 분위로 자르고, 같은 경계를 시험셋에 적용.
9. **누수 차단** – 입력은 모두 t 시점과 그 이전 정보. 결과(t+1~t+4) 변수는 입력에 없다. 학습행은 결과 시점이 시험 시작 전인 행만 쓴다.

가처분 빈곤선 (균등화 가처분소득 중위 50%, 2023년 가격, 연 만원)

2005	2010	2015	2019	2020	2021	2022	2023
1,147	1,473	1,552	1,792	1,834	1,753	1,747	1,779

3 정답 설계 – 왜 “3번 중 2번 이상 부족”인가

정답을 네 번 바꿔 보며 같은 시험 방식으로 채점했다. 핵심은 **지금 소득이 정답을 거의 다 정하는지**와 **정답에 일시적 잡음이 얼마나 섞였는지**다.

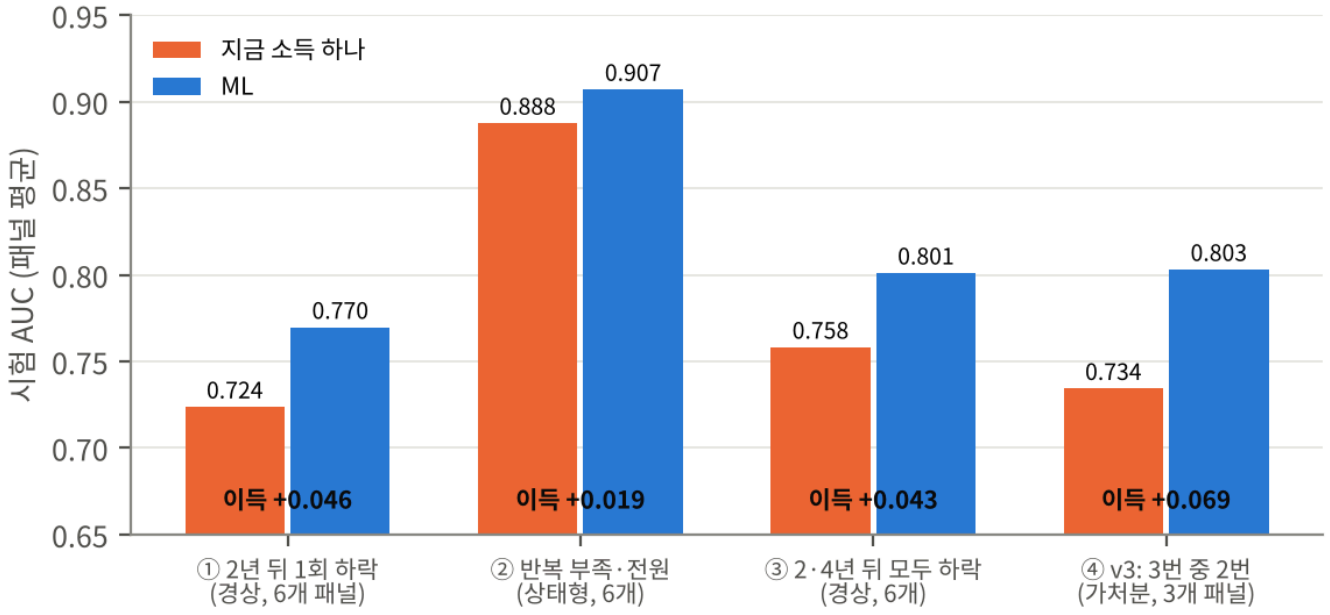


그림 1. 정답 정의별 시험 AUC(패널 평균). 굵은 글씨 = ML 이득.

정답	지금 소득	ML	이득	문제점
① 2년 뒤 1회라도 빈곤선 아래 (경상, 6개)	0.724	0.770	+0.046	선 근처에서 한 해만 출렁여도 1 → 정답 잡음
② 2·4년 뒤 모두 아래, 지금 가난한 사람 포함 (상태형)	0.888	0.907	+0.019	AUC는 높지만 지금 소득이 다 맞힘 – 기존 시스템이 이미 아는 사람
③ 지금 괜찮고 2·4년 뒤 모두 아래 (경상, 6개)	0.758	0.801	+0.043	잡음은 줄었지만 경상소득은 세금·보험료 차이로 생활 수준과 어긋남
④ v3: 지금 괜찮고 1~4년 뒤 3번 중 2번 이상 아래 (가처분, 3개)	**0.734**	**0.803**	**+0.069**	**반복 관측 + 가처분 + 역할 분담 → ML이 기여할 몫이 가장 큼**

v3 정답의 정확한 정의

대상: t 시점 50~69세이고, 균등화 가처분소득 ≥ 가처분 빈곤선(“지금은 괜찮음”).

결과: t+2, t+3, t+4 조사 중 2번 이상 빈곤선 아래면 1. t+2와 t+4는 반드시 관측돼야 한다. t+3가 없는 경우(격년 조사·결측)는 t+2와 t+4 **둘 다** 아래여야 1.

효과: 한 해만 출렁인 사람은 0이 된다 → 정답이 “일시적 잡음”이 아니라 “지속적 소득절벽”을 가리킨다.

AUC 숫자만 보면 ②가 가장 높다. 하지만 ②는 지금 가난한 사람이 2년·4년 뒤에도 가난하다는 걸 맞히는 문제라 지금 소득 하나로 이미 0.888이다. 사업적 가치(아직 안 보이는 사람을 먼저 찾기)와 ML의 기여가 모두 큰 것은 ④다. 그래서 ④를 주 정답으로 하고, ②는 비교용으로 남긴다.

4 검증 설계 – 미래를 보지 않는 시험

과제	학습 기준연도	학습 행	학습 하락률	시험 기준연도	시험 행	시험 인원	시험 하락률	입력 수
복지(가처분)	2006–2016	27,294	13.1%	2020·2021	4,984	2,840	6.0%	43
재정(가처분)	2008–2015	8,498	16.3%	2019·2020	3,699	2,303	10.3%	35
국민노후(가처분)	2007–2013	5,774	11.9%	2017·2019	1,752	1,152	9.9%	45
국민노후(필요생활비)	2007–2013	6,680	10.1%	2017·2019	1,887	1,252	10.4%	45
노동(경상·재현)	2005–2015	27,581	12.8%	2019·2020	10,496	6,092	9.9%	39
의료(경상·이식)	2009–2015	17,839	13.8%	2020·2021	5,034	3,099	8.4%	30
고령화(경상·이식)	2006–2012	10,198	10.9%	2016·2018	3,692	2,179	12.8%	43

1. **시험 봉인** – 4년 뒤 결과가 관측되는 최근 2개 기준 차수를 시험셋으로 떼어 둔다. 모델 선택·튜닝에 한 번도 쓰지 않는다.
2. **학습** – 결과 관측 기간(t+4)이 시험 시작 전에 끝나는 행만. 시험 직전 4년치는 결과가 겹쳐 버린다.
3. **튜닝** – 학습 구간의 마지막 2개 연도를 내부 검증으로 쓰고, 그보다 4년 앞까지로 학습해 격자(4개)와 반복 수를 고른 뒤 전체 학습 구간으로 재적합.
4. **판정** – 판정 3개 패널 각각에서 (모델 − 지금 소득) AUC 차이를 DeLong 공분산으로 구하고 DerSimonian–Laird 랜덤효과로 결합. 판정 기준: 결합 하한 > 0, 실질 기준 +0.03, 3개 중 3개 양수.
5. **보조** – 재현(노동)·이식(의료·고령화), 사람 단위 부트스트랩, 질문 수 고정, 학습곡선·셔플, 집단별, 처음 보는 사람, 보정.

사전 지정 모델은 LightGBM 단독(v3 첫 실행에서 지정). 최종 서비스 모델(LightGBM+로지스틱 순위 평균)은 v3 탐색 과정에서 정했으므로 두 결과를 함께 보고한다.

5 주결과 – 판정

과제	최종 – 지금 소득	p	LightGBM(사전) – 지금 소득	p	최종 – 계산기형	p
복지(가처분)	+0.058 ±0.014	<0.001	+0.050	<0.001	+0.034	<0.001
재정(가처분)	+0.070 ±0.022	<0.001	+0.067	<0.001	+0.045	<0.001
국민노후(가처분)	+0.078 ±0.030	<0.001	+0.074	<0.001	+0.048	0.002
국민노후(필요생활비)	+0.089 ±0.027	<0.001	+0.080	<0.001	+0.073	<0.001
노동(경상·재현)	+0.056 ±0.011	<0.001	+0.051	<0.001	+0.026	<0.001
판정 3개 결합	**+0.064 [+0.053, +0.075]**	**<0.001**	**+0.060 [+0.045, +0.075]**	**<0.001**	**+0.038**	**<0.001**

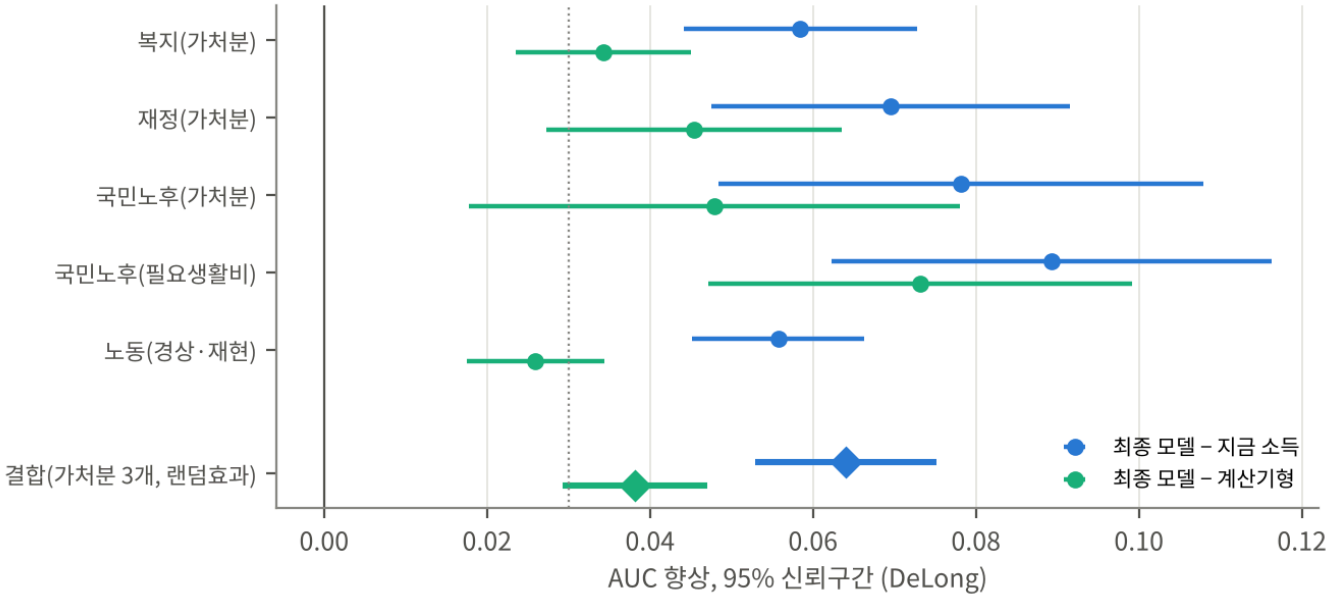


그림 2. 과제별 AUC 향상(95% CI)과 판정 3개 패널 결합(마름모). 점선 = 실질 기준 +0.03. 이질성 I^2 = 0%.

판정: 지지됨

① 결합 하한 +0.053 > 0 **통과** ② 결합 추정 +0.064 ≥ +0.03 **통과** ③ 판정 3개 중 3개 양수 **통과**. 사전 지정 LightGBM 단독도 +0.060 [+0.045, +0.075]로 같은 결론이다. 사람이 만든 계산기형(소득·나이·취업 로지스틱)보다도 +0.038 높다.

6 모델 비교 – 신경망 제외 15종 + 기준 2종 + 최종 앙상블

모든 모델은 과제마다 같은 학습셋·같은 입력·같은 시험셋을 썼다. 부스팅 4종(HistGB·XGBoost·LightGBM·CatBoost)은 내부 검증으로 격자와 반복 수를 골랐고, 나머지는 고정 설정이다.

모델	복지(가처분)	재정(가처분)	국민노후(가처분)	국민노후(필요생활비)	노동(경상·재현)	판정 3개 평균
최종: LightGBM+로지스틱	**0.870**	**0.794**	**0.746**	**0.796**	**0.807**	**0.803**
LR_L1	0.875	0.795	0.735	0.780	0.804	**0.801**
ExtraTrees	0.861	0.784	0.759	0.803	0.792	**0.801**
CatBoost	0.866	0.793	0.743	0.792	0.806	**0.800**
GAM_Spline_LR	0.872	0.789	0.740	0.783	0.807	**0.800**
XGBoost	0.857	0.787	0.752	0.787	0.801	**0.799**
LightGBM	0.861	0.791	0.742	0.787	0.802	**0.798**
RandomForest	0.859	0.793	0.741	0.777	0.799	**0.798**
LR_L2	0.874	0.786	0.732	0.780	0.804	**0.798**
AdaBoost	0.861	0.782	0.742	0.772	0.801	**0.795**
GradientBoosting	0.863	0.790	0.728	0.784	0.805	**0.794**
HistGB	0.860	0.791	0.730	0.787	0.802	**0.793**
LDA	0.868	0.777	0.728	0.769	0.796	**0.791**
KNN_k101	0.849	0.758	0.711	0.752	0.772	**0.773**
B1 계산기형	0.835	0.748	0.698	0.723	0.781	**0.760**
DecisionTree	0.827	0.744	0.700	0.725	0.766	**0.757**
B0 지금 소득	0.811	0.724	0.668	0.706	0.751	**0.734**
GaussianNB	0.807	0.729	0.605	0.524	0.749	**0.714**

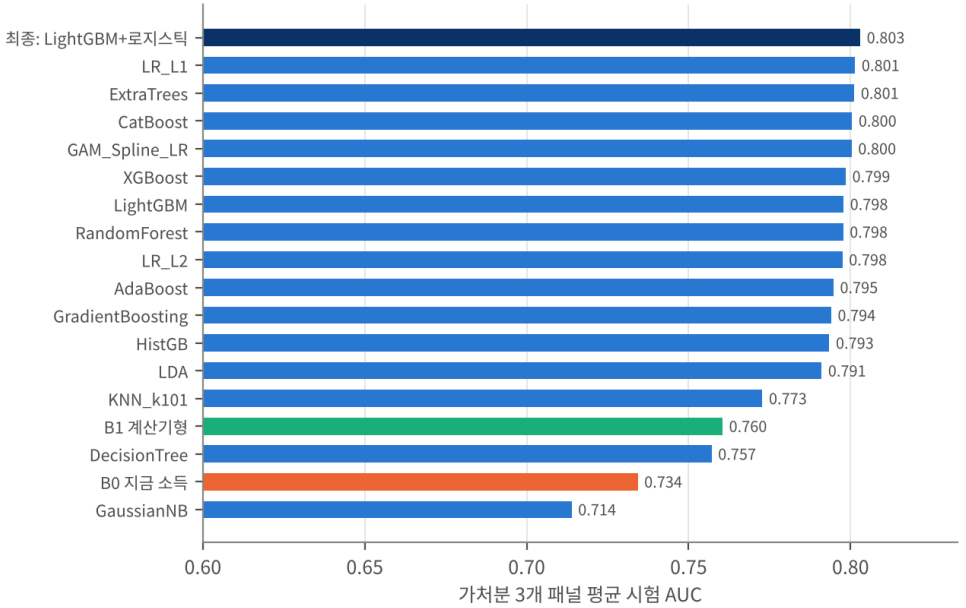


그림 3. 판정 3개 패널 평균 시험 AUC. 주황 = 지금 소득, 초록 = 계산기형, 진한 파랑 = 최종 앙상블.

읽는 법

- **모든 학습 모델이 기준선 위**에 있다. 정보(이력·취업·연금·자산) 자체가 가치가 있다는 뜻이다.
- **상위권은 로지스틱·GAM·부스팅·앙상블이 촘촘히 붙어 있다.** 서로 다른 계열이 같은 높이에서 멈춘다는 것은 데이터에 있는 신호를 거의 다 뽑아냈다는 신호다.
- **하위권(나이브베이즈·단일 트리·KNN)**은 변수 독립 가정·과적합·고차원 거리 문제로 손해를 본다. 모델 선택이 결과를 바꾼다.
- LightGBM과 로지스틱은 패널별로 우열이 바뀐다(복지는 로지스틱, 국민노후는 LightGBM). 그래서 최종 모델은 둘의 순위를 평균한다.

부스팅 튜닝 결과 (판정 3개 패널)

과제	모델	선택된 설정	반복	내부 검증 AUC
복지(가처분)	HistGB	{'max_leaf_nodes': 15, 'min_samples_leaf': 40}	117	0.851
복지(가처분)	XGBoost	{'max_depth': 3, 'min_child_weight': 5}	117	0.857
복지(가처분)	LightGBM	{'num_leaves': 15, 'min_child_samples': 150}	151	0.855
복지(가처분)	CatBoost	{'depth': 4, 'l2_leaf_reg': 3}	261	0.859
재정(가처분)	HistGB	{'max_leaf_nodes': 15, 'min_samples_leaf': 150}	83	0.776
재정(가처분)	XGBoost	{'max_depth': 5, 'min_child_weight': 5}	50	0.783
재정(가처분)	LightGBM	{'num_leaves': 15, 'min_child_samples': 40}	105	0.785
재정(가처분)	CatBoost	{'depth': 6, 'l2_leaf_reg': 10}	50	0.786
국민노후(가처분)	HistGB	{'max_leaf_nodes': 15, 'min_samples_leaf': 150}	70	0.699
국민노후(가처분)	XGBoost	{'max_depth': 3, 'min_child_weight': 5}	151	0.707
국민노후(가처분)	LightGBM	{'num_leaves': 15, 'min_child_samples': 150}	78	0.694
국민노후(가처분)	CatBoost	{'depth': 4, 'l2_leaf_reg': 10}	51	0.722

7 사람 단위 부트스트랩 – 보수적인 신뢰구간

시험셋에는 같은 사람이 두 기준 차수에 나올 수 있다. 행을 독립으로 보는 DeLong 표준오차는 이를 과소평가할 수 있다. 그래서 **사람**을 단위로 300번 다시 뽑아(그 사람의 모든 행을 함께) AUC 차이의 분포를 구했다.

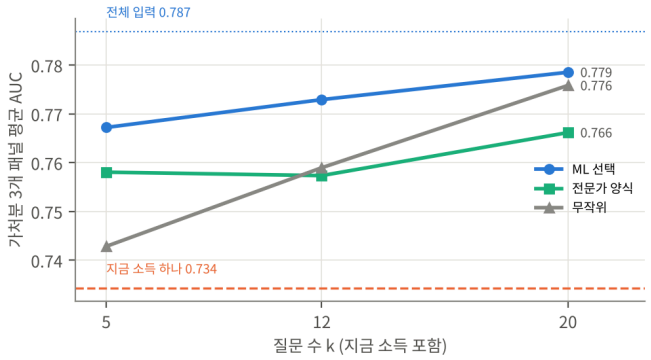
과제	비교	시험 인원	Δ AUC	부트스트랩 SE	95% 구간(백분위)	DeLong SE
복지(가처분)	최종–지금소득	2,840	+0.058	0.0081	[+0.044, +0.076]	0.0073
복지(가처분)	최종–계산기형	2,840	+0.034	0.0059	[+0.024, +0.046]	0.0055
복지(가처분)	LightGBM–로지스틱	2,840	-0.013	0.0028	[-0.019, -0.007]	0.0028
재정(가처분)	최종–지금소득	2,303	+0.070	0.0122	[+0.044, +0.093]	0.0112
재정(가처분)	최종–계산기형	2,303	+0.045	0.0098	[+0.027, +0.065]	0.0092
재정(가처분)	LightGBM–로지스틱	2,303	+0.005	0.0053	[-0.007, +0.015]	0.0050
국민노후(가처분)	최종–지금소득	1,152	+0.078	0.0154	[+0.050, +0.107]	0.0152
국민노후(가처분)	최종–계산기형	1,152	+0.048	0.0157	[+0.017, +0.078]	0.0154
국민노후(가처분)	LightGBM–로지스틱	1,152	+0.010	0.0124	[-0.014, +0.035]	0.0122
국민노후(필요생활비)	최종–지금소득	1,252	+0.089	0.0132	[+0.063, +0.118]	0.0138
국민노후(필요생활비)	최종–계산기형	1,252	+0.073	0.0125	[+0.051, +0.098]	0.0133
국민노후(필요생활비)	LightGBM–로지스틱	1,252	+0.007	0.0124	[-0.017, +0.032]	0.0121
노동(경상·재현)	최종–지금소득	6,092	+0.056	0.0061	[+0.043, +0.068]	0.0054
노동(경상·재현)	최종–계산기형	6,092	+0.026	0.0051	[+0.016, +0.036]	0.0043
노동(경상·재현)	LightGBM–로지스틱	6,092	-0.002	0.0033	[-0.008, +0.004]	0.0028
판정 3개 결합	**LightGBM–로지스틱**		**-0.002**	**0.0079**	**[-0.017, +0.014]**	
판정 3개 결합	**최종–계산기형**		**+0.038**	**0.0048**	**[+0.029, +0.048]**	
판정 3개 결합	**최종–지금소득**		**+0.064**	**0.0062**	**[+0.052, +0.077]**	

해석

부트스트랩 표준오차는 DeLong보다 대체로 조금 크지만, 결합 결론(최종 – 지금 소득 +0.064, 하한 +0.052)은 그대로다. LightGBM – 로지스틱은 -0.002 [-0.017, +0.014]로 0을 포함한다. 부스팅이 로지스틱보다 확실히 낫다고는 말할 수 없다. 이득의 주원천은 모델 계열이 아니라 **어떤 정보를 학습했느냐**다.

8 질문 수 고정 비교 – “변수가 많아서 이긴 것 아닌가”

물어보는 질문 수를 똑같이 맞추고 비교했다. 모든 묶음에 “지금 소득”을 포함하고, 나머지 k−1개를 ① ML이 고른 순서 ② 노후준비 진단표에 흔한 전문가 양식 순서(나이·취업·배우자·가구원·연금·자가·금융자산·부채·건강…) ③ 무작위(3회 평균)로 채운다. ML의 순서는 **학습 구간 안의 내부 검증 순열 중요도**로만 정했다(시험셋을 보지 않음).



질문 수	ML 선택	전문가 양식	무작위	ML 선택+로지스틱
5개	**0.767**	0.758	0.743	0.780
12개	**0.773**	0.757	0.759	0.799
20개	**0.779**	0.766	0.776	0.799

판정 3개 패널 평균. 같은 고정 설정의 LightGBM.

같은 질문 수에서 ML이 고른 묶음이 가장 높다. 데이터가 **무엇을 물을지**를 고르면 같은 설문 길이로 더 잘 찾는다. 이것이 대화형 진단(12문항) 설계의 근거다.

ML이 고른 12문항 (패널별)

과제	질문 (중요 순)
복지(가처분)	지금 가처분소득/빈곤선 · 현재 소득/빈곤선 · 최근 4년 최저 소득 · 1년 소득 변화 · 가구원 수 · 나이 · 학력 · 부채(로그) · 2년 전 본인 근로소득 · 직종 · 본인 근로소득 비중 · 2년 가처분소득 변화
재정(가처분)	지금 가처분소득/빈곤선 · 현재 소득/빈곤선 · 1년 소득 변화 · 최근 4년 최저 소득 · 학력 · 2년 소득 변화 · 나이 · 지역 · 금융자산(로그) · 소득 변동성 · 연금 개시까지 거리 · 현재 취업
국민노후 (가처분)	지금 가처분소득/빈곤선 · 현재 소득/빈곤선 · 최근 4년 최저 소득 · 나이 · 2년 내 실직 · 필요 최소생활비 · 사적이전 비중 · 공적이전 비중 · 60세까지 거리 · 가구 근로·사업소득 비중 · 2년 전 건강 · 공적연금 가입

9 학습곡선과 라벨 셔플 – “계산기가 아니라 학습했다”

계산기는 정해진 공식이라 데이터를 더 줘도 달라지지 않는다. 학습된 모델은 데이터가 늘수록 좋아지고, 우연(섞인 정답)에서는 아무것도 배우지 못한다. 판정 3개 + 노동패널의 학습셋을 합친 통합 모델(공통 입력 + 가처분 소득비)로 확인했다. 통합 시험 AUC는 0.801(지금 소득 0.751)이다.

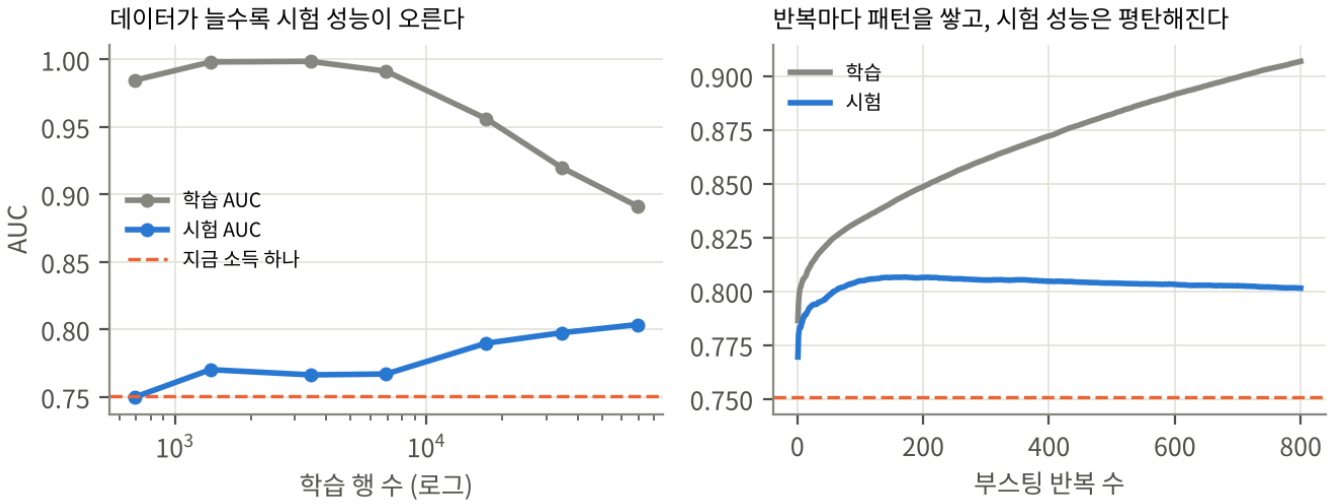
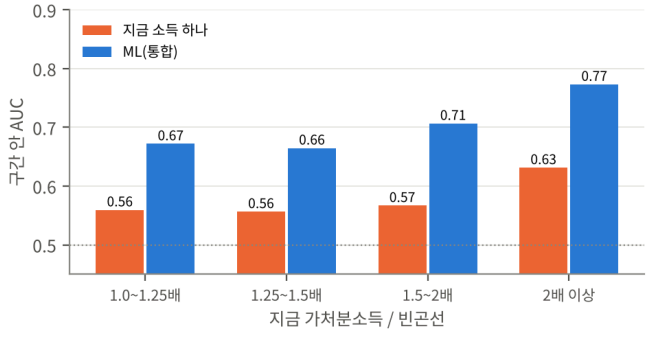


그림 5. 왼쪽: 학습 행 691 → 69,147에서 시험 AUC 0.750 → 0.804, 학습–시험 격차 0.235 → 0.088. 오른쪽: 부스팅 반복에 따른 학습·시험 AUC.

- **데이터가 늘수록** 시험 AUC가 오르고 학습–시험 격차는 줄어든다. 적은 데이터에서는 외우고(과적합), 많아지면 일반화한다.
- **반복에 따라** 시험 AUC가 빠르게 오른 뒤 평탄해진다. 오래 학습해도 시험 성능이 무너지지 않는다(과적합 통제).
- **라벨 셔플**: 학습셋의 정답만 무작위로 섞어 같은 모델을 5번 학습하면 시험 AUC가 평균 0.486(범위 0.445~0.512)다. 원래 정답의 0.801에 한 번도 가까이 가지 못한다. 모델이 찾은 것은 정답과 연결된 실제 신호다.

소득이 같은 사람들 사이에서도 구별한다



지금 소득 구간 안에서는 소득 차이가 작아서 지금 소득만으로는 동전 던지기에 가깝다(AUC 0.56~0.63). ML은 구간 안에서도 0.66~0.77를 유지한다.

빈곤선 바로 위(1.0~1.25배, 2,910행, 하락률 24.6%)는 사업상 가장 중요한 구간이다. 여기서 지금 소득 0.56 vs ML 0.67. 소득 밖의 정보를 학습했다는 가장 직접적인 증거다.

10 중요도와 부분의존 – 무엇을 보고 판단하나

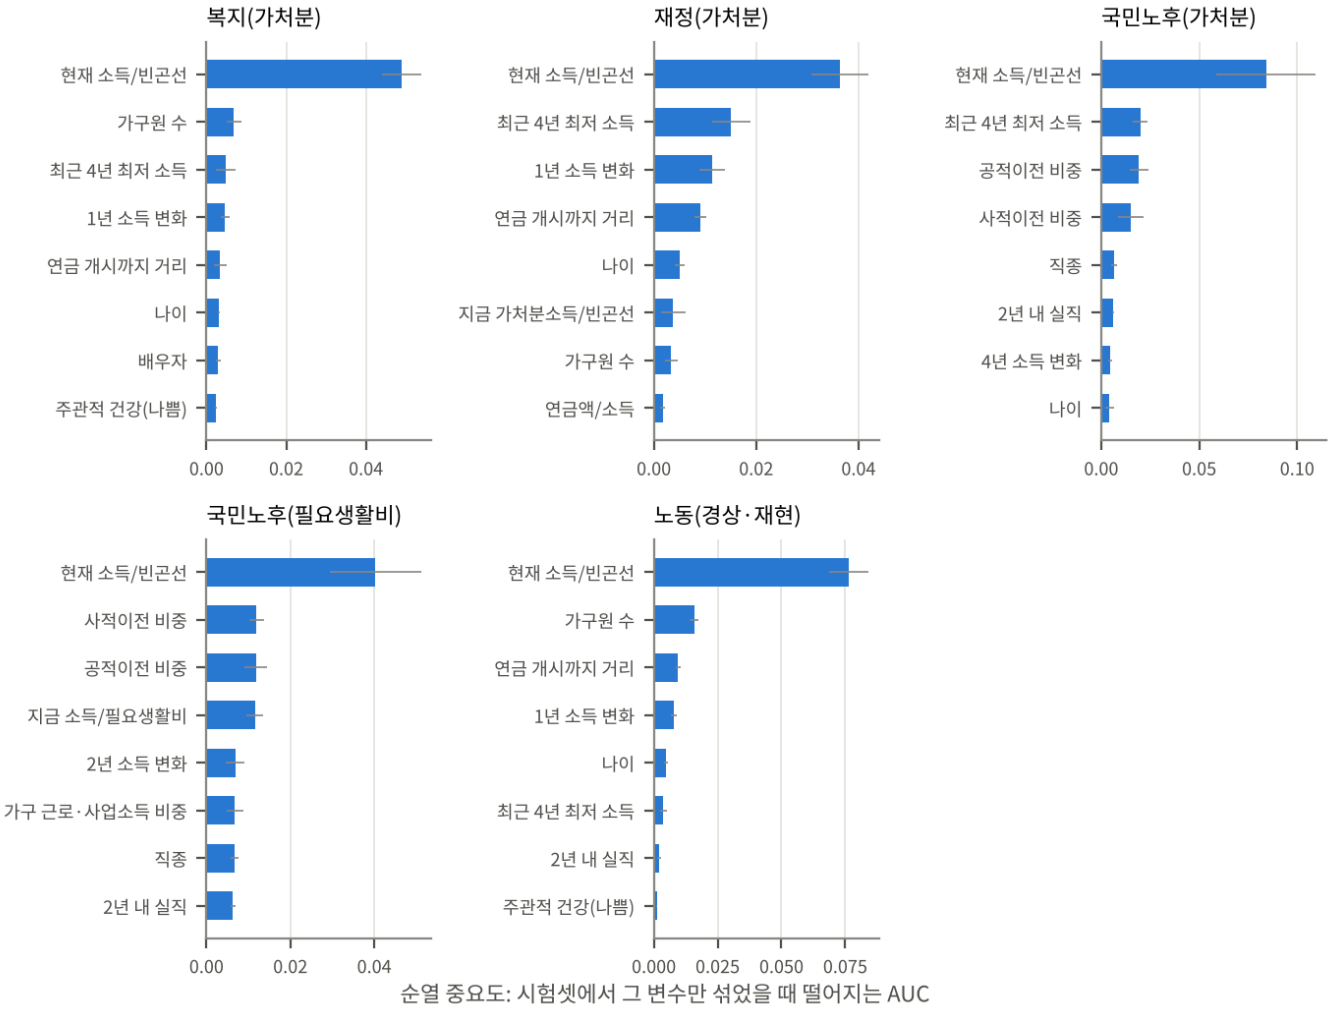


그림 6. 과제별 순열 중요도 상위 8개(시험셋, LightGBM). 막대 = 그 변수만 섞었을 때 떨어지는 AUC, 가는 선 = 5회 반복 표준편차.

> **순열 중요도** – 시험셋에서 한 변수의 값만 사람들 사이에 무작위로 섞었을 때 AUC가 얼마나 떨어지는지. 많이 떨어질수록 모델이 그 변수에 기대고 있다.

지금 소득이 대체로 1위지만, 그다음을 **소득 이력**(최근 4년 최저 소득, 2년·4년 변화, 변동성)과 **소득 구성**(공적이전·근로소득 비중), **일과 나이**(취업, 연금 개시까지 거리)가 채운다. 모델은 “지금 얼마 버나”에 더해 “그 소득이 무엇으로 이루어졌고 얼마나 흔들려 왔나”를 본다.

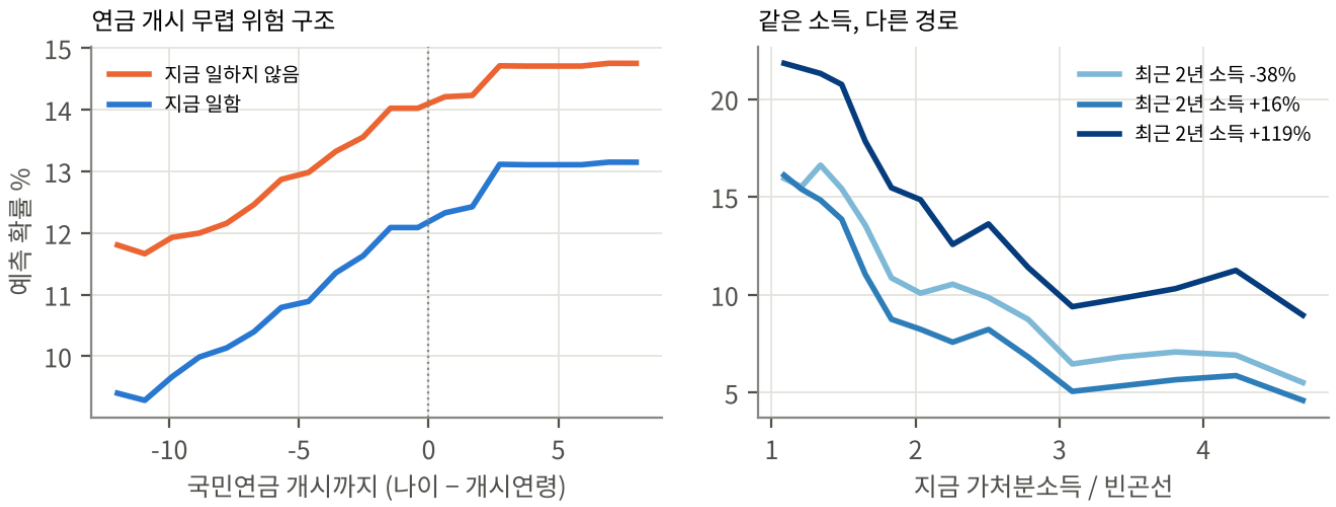


그림 7. 부분의존(다른 변수는 그대로 두고 한 변수만 바꿨을 때의 평균 예측 확률). 통합 모델.

> **부분의존** – 모든 사람의 한 변수를 같은 값으로 바꿔 놓고 예측 확률의 평균을 구한 것. 그 변수가 위험에 어떤 모양으로 작용하는지 보여준다.

왼쪽: 국민연금 개시연령 13년 전 → 개시 이후로 갈수록 위험이 바뀐다(일함 9.4% → 13.1%, 일하지 않음 11.8% → 14.7%). 정년과 연금 개시 사이 “소득 크레바스”의 데이터상 모양이다. **오른쪽**: 같은 소득 위치라도 최근 2년간 소득이 어떻게 움직였느냐에 따라 위험이 다르다. 모델은 일시적 소득과 안정적 소득을 구별한다.

11 집단별 점검과 처음 보는 사람 채점

집단별 – 특정 집단에서만 맞는 것 아닌가

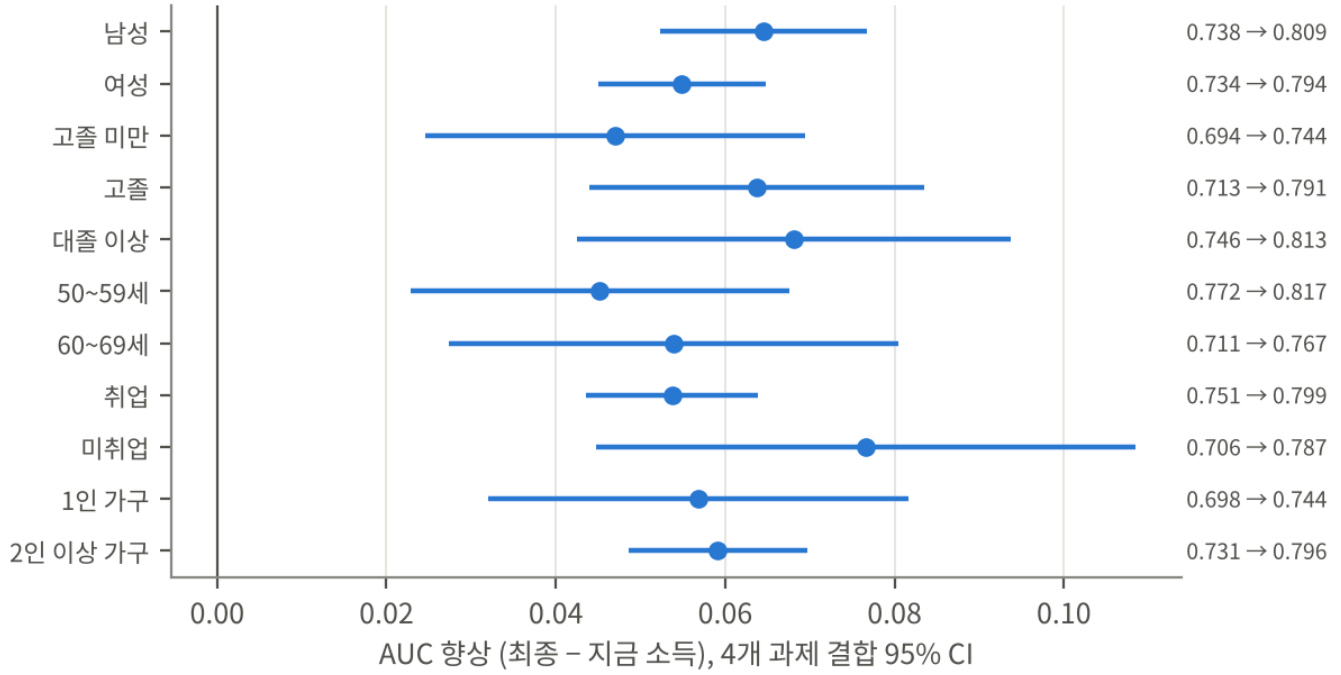


그림 8. 성별·학력·나이대·취업·가구형태별 AUC 향상(최종 – 지금 소득). 판정 3개 + 노동패널 4개 과제 결합. 오른쪽 = 평균 AUC(지금 소득 → 최종).

모든 집단에서 향상이 양수다. 특히 지금 소득만으로는 가장 구별이 어려운 집단(미취업, 60대)에서도 ML이 일관되게 더한다. 서비스를 특정 집단에만 써야 하는 제약은 보이지 않는다.

처음 보는 사람 – 같은 사람을 다시 맞힌 것 아닌가

시험셋 가운데 **사람도 가구도 학습셋에 한 번도 나오지 않은** 행만 골라 따로 채점했다(신규 표본·분가 가구).

과제	처음 보는 사람 행	시험셋 중 비율	지금 소득	최종 모델	Δ	p
복지(가처분)	818	16%	0.837	0.896	+0.059	<0.001
재정(가처분)	1,083	29%	0.774	0.838	+0.064	0.004
국민노후(가처분)	241	14%	0.635	0.706	+0.071	0.082
국민노후(필요생활비)	226	12%	0.749	0.813	+0.063	0.051
노동(경상·재현)	5,339	51%	0.750	0.815	+0.066	<0.001

결합: +0.065 [+0.051, +0.078]. 처음 보는 사람에서도 향상이 유지된다.

국민노후패널처럼 시험기간에 신규 표본이 없는 패널은 처음 보는 사람이 적어(하락자 15명 미만) 채점하지 않았다.

12 보정과 이식 – 확률은 맞나, 다른 기관에 옮겨도 되나

> **보정** – 모델이 “20%”라고 한 사람들 중 실제로 20% 정도가 떨어지는지. 순위(AUC)가 맞아도 확률 수준은 어긋날 수 있다.
> **Platt 재보정** – 모델 점수를 그대로 두고, 최근 자료로 “점수 → 확률” 변환식(로지스틱 한 줄)만 다시 맞추는 것. 순위는 바뀌지 않는다.

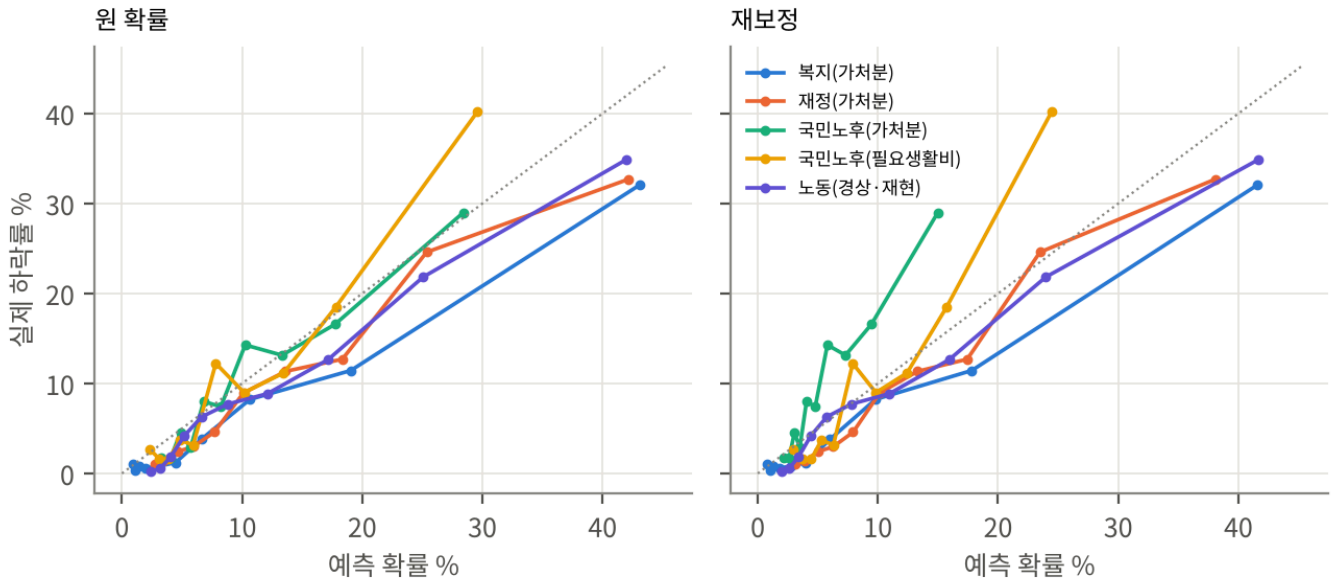


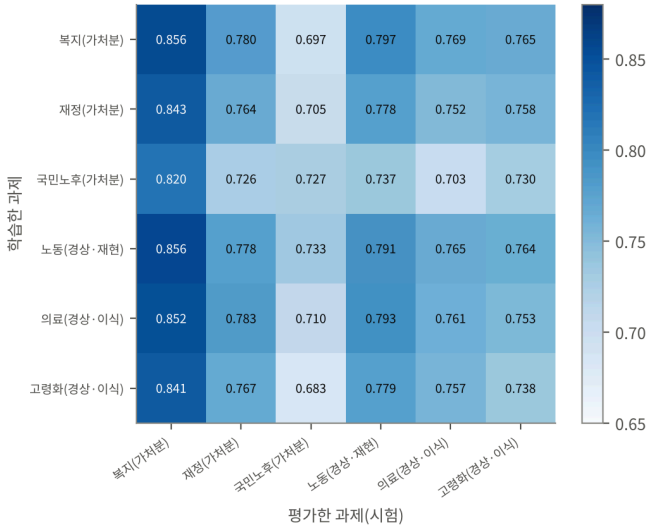
그림 9. 예측 확률 10분위별 실제 하락률. 왼쪽 원 확률, 오른쪽 학습구간 마지막 연도로 재보정한 확률. 대각선에 가까울수록 정직한 확률.

과제	확률	평균 예측	실제	ECE	Brier	Brier(평균만)
복지(가처분)	원 확률	9.2%	6.0%	3.2%p	0.0496	0.0567
복지(가처분)	재보정	8.7%	6.0%	2.7%p	0.0490	0.0567
재정(가처분)	원 확률	13.4%	10.3%	3.1%p	0.0827	0.0922
재정(가처분)	재보정	12.9%	10.3%	2.8%p	0.0821	0.0922
국민노후(가처분)	원 확률	10.3%	9.9%	1.5%p	0.0831	0.0895
국민노후(가처분)	재보정	5.8%	9.9%	4.6%p	0.0864	0.0895
국민노후(필요생활비)	원 확률	9.9%	10.4%	2.7%p	0.0815	0.0931
국민노후(필요생활비)	재보정	9.3%	10.4%	3.5%p	0.0829	0.0931
노동(경상·재현)	원 확률	12.7%	9.9%	2.8%p	0.0788	0.0893
노동(경상·재현)	재보정	11.8%	9.9%	2.0%p	0.0784	0.0893

원 확률은 대체로 대각선 근처지만 시험기간 하락률이 학습기간보다 낮은 패널(복지·재정·노동)은 다소 높게 나온다. 학습구간 마지막 연도로 재보정하면 이 세 과제는 ECE가 줄어든다. 반면 **국민노후패널은 재보정 후 오히려 나빠졌다**(가처분 1.5%p → 4.6%p). 재보정에 쓴 내부 검증 표본이 작고(수백 명) 그 시기의 하락률이 시험기간과 달랐기 때문이다. 운영에서는 **표본이 충분한 최근 자료로만 재보정**하고, 작을 때는 원 확률을 쓰는 규칙이 필요하다.

ECE = 10분위별 |예측−실제|의 가중 평균. Brier = (예측−실제)² 평균, 낮을수록 좋음. “Brier(평균만)”은 모두에게 평균 하락률을 준 경우.

이식 – 한 패널에서 학습해 다른 패널에 적용



공통 입력만으로 학습한 모델을 다른 과제의 시험셋에 그대로 적용했다(행 = 학습, 열 = 시험). 비대각선(다른 패널) 평균 0.766, 최저 0.683. 조사 기관·문항·표본이 달라도 같은 위험 구조가 반복된다.

순위는 유지되지만 확률 수준은 어긋난다. 그대로 옮기면 평균 예측과 실제 하락률이 평균 6.0%p(최대 18.0%p) 차이 난다. 대상 패널의 최근 학습 자료로 **확률만 재보정**하면 4.1%p(최대 16.1%p)로 줄어든다. 재학습 없이 이식할 수 있다는 뜻이다.

국민노후패널(열)은 어느 패널에서 학습해도 0.68~0.73으로 낮다. 국민노후는 표본이 고령 쪽으로 치우쳐 있고 소득 구성(공적이전 비중)이 달라, 공통 입력만으로는 구조를 다 옮기지 못한다. 이 패널은 자체 추가 입력(소득 구성·필요 생활비)이 있을 때 0.75~0.80으로 오른다.

이전 실험의 “복지패널 이식 실패(예측 61% vs 실제 26%)”는 순위가 아니라 확률 수준의 문제였다. 재보정으로 평균 오차가 줄지만(최대 오차가 남는 쌍도 있음), 실제 이식 때는 대상 기관 자료로 재보정 후 한 번 더 확인하는 절차가 필요하다.

13 비즈니스 모델 – “소득절벽 조기경보”

모델이 파는 것은 점수가 아니라 **시간**이다. 지금 소득 기준으로는 아무 문제가 없어 보이는 사람에게 미리 알리면 재취업, 연금 수령 시점 조정, 자산 유동화, 복지 연계를 할 수 있다.

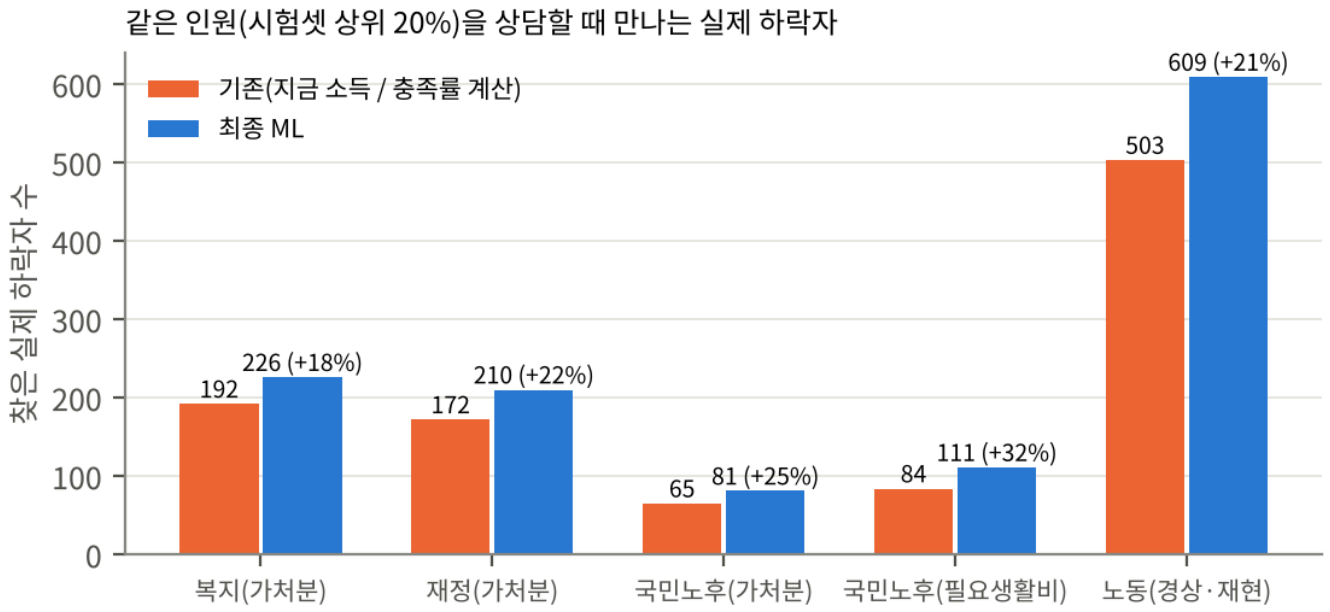


그림 10. 시험셋 상위 20%를 상담할 때 만나는 실제 하락자 수. 국민노후(필요생활비)의 “기존”은 충족률 계산이다.

과제	상담 인원(상위 20%)	전체 하락자	지금 소득	계산기형	최종 ML	더 찾음	포착률
복지(가처분)	996	301	192	209	**226**	**+18%**	64% → 75%
재정(가처분)	739	380	172	178	**210**	**+22%**	45% → 55%
국민노후(가처분)	350	174	65	75	**81**	**+25%**	37% → 47%
국민노후(필요생활비)	377	196	84	89	**111**	**+32%**	43% → 57%
노동(경상·재현)	2,099	1,040	503	550	**609**	**+21%**	48% → 59%

3층 구조

층	고객 · 결제자	제공 가치	수익
① **대화형 진단** “소득절벽 점수”	50~64세 개인 (무료)	12문항 대화(8장의 ML 선택 문항) → 앞으로 몇 년 안 지속 하락 확률 + 이유 3가지(예: “가구소득의 80%가 본인 임금, 연금 개시까지 4년”) + 처방 카드(재취업·연금 연기·주택연금·복지 연계)	무료. 동의 기반 리드 → ②③으로 연결
② **기관용 조기경보 API**	지자체 복지 사각지대 발굴, 고용센터·중장년 재취업 지원(의무 기업 포함), 국민연금 노후준비서비스	보유 명단에 점수를 붙여 상위부터 상담. 같은 상담 인력으로 하락자를 +18%~+32% 더 만남	건당 과금 또는 연간 라이선스 + 확률 재보정 유지보수
③ **브릿지 신탁** (노후 신탁 연계)	은행·증권 신탁부문, 퇴직연금 사업자	위험 상위 고객에게 “정년 ~ 연금 개시” 공백기에 매월 지급하는 신탁·IRP 인출 플랜을 미리 제안. 점수는 상품 추천·지급 설계의 근거	신탁 보수 분배, 판매 성과 연동

사용자 아이디어 4개 평가

아이디어	이 결과가 주는 근거	판단
내 노후걱정이 실제로 이어질지 (개인 진단)	12문항으로 전체 입력과 거의 같은 성능(8장). 국민노후패널의 본인 걱정 문항은 기준선 비교에서 약했다(이전 분석: 걱정 AUC 0.54 vs ML 0.66).	**강함** – B2C 유입
국민연금공단 결과가 적절한가	공단의 실제 진단 결과는 데이터에 없어 직접 비교는 불가. 대신 공단 패널의 필요 생활비로 만든 충족률 계산보다 같은 인원에서 32% 더 찾는다.	**표현 주의** – “보완 지표” 제안
재취업지원서비스 · 복지 사각지대 발굴	빈곤선 바로 위 집단에서 지금 소득 0.56 vs ML 0.67. 소득 기준 발굴이 원리상 못 보는 사람을 찾는다. 미취업·60대 집단에서도 향상 유지.	**가장 강함** – B2G 핵심
개인 대화형 진단	중요도·부분의존의 상위 패턴(소득 이력, 연금 개시까지 거리, 일의 형태)이 그대로 문항과 이유 설명이 된다.	**강함** – 진단의 형태

차별점

- **시간 차**: 기존 소득·재산 조사형 발굴은 이미 떨어진 사람을 찾는다. 이 모델은 아직 기준 위에 있는 사람을 먼저 찾는다.
- **현장 판단을 이김**: 소득 하나, 계산기형 규칙, 충족률 계산 모두보다 같은 인원으로 더 많이 찾는다.
- **여러 국가 패널에서 재현·이식**: 한 데이터에 맞춘 모델이 아니다. 다른 기관으로 옮기면 순위는 유지되고, 확률은 대상 기관 자료로 재보정한 뒤 확인한다(E4: 한 가지 보정법이 모든 패널에 맞지는 않았다).
- **짧은 설문으로 작동**: 12문항이면 전체 입력과 비슷하다. 기관마다 가진 변수가 달라도 시작할 수 있다.

시장 진입 순서

1. **파일럿(3개월)** – 지자체 1곳 또는 은행 1곳의 기존 명단(50~64세)에 적용. 과거 4년 자료로 백테스트 리포트 제공.
2. **B2G 확장** – 복지 사각지대 발굴 지표에 “지속 소득절벽 위험” 1개 축 추가 제안.
3. **금융 연계** – 브릿지 신탁 공동 설계. 고객 동의 하에 실제 소득 흐름 자료로 재학습해 성능을 높인다.

규제: 개인신용정보·민감정보(건강) 사용 시 동의·가명처리 필요. 기관용은 건강 변수를 뺀 공통 입력 모델로 시작하면 부담이 작다.

13-1 기술 설계도 – 3층 서비스가 하나의 엔진을 공유한다

세 층은 각각 다른 시스템이 아니다. **하나의 예측 엔진**에 입력 경로와 출력 화면만 다르게 붙인다. 숫자는 역할을 나눈다: **ML은 확률·순위·이유**, **규칙 엔진은 원 단위 금액**, 대화 AI는 문장만 만든다.

① 입력

개인 대화
ML이 고른 12문항
지금 소득부터, 중요도 순서로

기관 명단 업로드
지자체·고용센터·연금공단
보유 항목만 (결측 허용)

금융사 고객 정보
본인 동의 시
소득·자산·연금 가입 이력

↓

② 데이터 처리 (전처리 파이프라인과 동일)

표준 스키마
항목 이름·단위 통일

→

소득 척도
2023년 가격 · 균등화 · 빈곤선 대비

→

이력 변수
2·4년 변화 · 최저 · 변동성 · 연금 개시까지

→

결측 표시
없는 항목은 비워 둔 채 예측

↓

③ ML 코어

지속 소득 하락
LightGBM + 로지스틱
복지 0.870 · 계산 대비 +0.038

그만둠 (T1)
LightGBM
계산기형 대비 +0.104 · 6/6 통과

재취업 (T2)
LightGBM
계산기형 대비 +0.142 · 6/6 통과

개인별 이유
TreeSHAP 기여도 상위 3개
충실도 무작위 대비 4.4~6.5배

판단 보류 · 닮은 30명
conformal (α = 0.10) · 가중 KNN
"안전" 중 실제 하락 1.0%~3.0%

가장 작은 변화
반사실 탐색 (방향 일치 확인)
적응형 질문은 다음 단계(2/5)

↓

④ 판정 · 규칙 (ML 바깥)

위험 구간
상위 10% / 10~30% / 나머지 (+ 판단 보류)

+

규칙 엔진
부족 금액을 제도(기초연금 등)·집(주택연금)·준비로 나눠 원 단위 계산

+

문장 생성
대화 AI는 숫자를 만들지 않고 설명 문장만

↓

⑤ 출력 = 3층

① 진단 카드 (개인, 무료)
계산 결과 vs 실제 위험 4칸 · 이유 3가지 · 채우기 계획 · 2년 뒤 재점검

② 우선 상담 목록 (기관) ★ 첫 제품
명단 → 위험 구간 · 이유 · 판단 보류 표시 CSV/API · 그만둠·재취업 확률로 서비스 강도 배분

③ 브릿지 신탁 제안 (금융)
정년~연금 개시 공백기 월 지급 설계 · 동의 고객만

운영 루프 – 새 조사 차수·기관 결과가 쌓이면 연 1회 재학습, 확률은 대상 기관 최근 자료로 재보정 후 확인(E4 결과 반영), 구간별 실제 부족률을 분기마다 모니터링. 개인정보: 동의·가명처리, 기관용은 건강 변수를 뺀 공통 입력부터.

첫 제품(MVP) 한 장

고객 지자체 복지 사각지대 발굴 담당 · 재취업지원서비스 운영기관 | **입력** 보유 명단(결측 허용) | **출력** 우선 상담 순위 + 이유 3가지 + 판단 보류 | **성과 지표** 같은 상담 인원으로 만나는 실제 하락자 수(시험: +18~32%) | **과금** 연간 이용 계약(진단 건수 기준)

15 추가 실험 (D16 검토 후) – E1 · E1b · E2 · E4

D16 보고서를 검토해 우리 서비스에 없던 요소를 골라, 넣기 전에 실험으로 검증했다. 판정 규칙은 실행 전에 파일로 고정했다 (prereg_E124.txt).

15-1. 노후 계산의 2차 검진 (국민노후보장패널)

E1 (규칙상 성공, 설계 실수 발견) – 계산 가능자 전체로 위험 구간 경계를 정했다. 계산 × ML 위험 표는 아래와 같고 판정 규칙은 통과했지만, 계산상 괜찮은 집단의 "높음"이 10명뿐이었다.

계산	ML 위험	인원	실제 4년 반복 부족	95% CI
계산상 괜찮음	낮음	1,291	4.6%	[3.6%, 5.9%]
계산상 괜찮음	중간	586	22.2%	[19.0%, 25.7%]
계산상 괜찮음	높음	10	60.0%	[31.3%, 83.2%]
계산상 괜찮음	전체	1,887	10.4%	[9.1%, 11.8%]
계산상 부족	낮음	7	42.9%	[15.8%, 75.0%]
계산상 부족	중간	317	53.9%	[48.4%, 59.4%]
계산상 부족	높음	429	81.8%	[77.9%, 85.2%]
계산상 부족	전체	753	69.7%	[66.3%, 72.9%]

E1b – E1 설계 실수 보완 (성공). 서비스는 계산상 괜찮은 사람 안에서 우선순위를 정하므로, 경계를 그 집단 기준(학습셋 교차 예측 점수 분위)으로 다시 정의했다. 판정은 처음 채점하는 두 시점(O1·O2)으로 하고, E1과 같은 시험셋(O3)은 참고로 보고한다.

시점	기준연도	인원	반복 부족	충족률 AUC	ML AUC	상위 10% 찾은 수	상위 20%	ML 상위 10%	10~30%	나머지 70%
O1	2013·2015	2,825	5.8%	0.687	**0.710**	35 → **39**	74 → **77**	13.9%	10.8%	2.9%
O2	2015·2017	2,475	9.9%	0.734	**0.791**	70 → **89**	123 → **148**	37.1%	17.5%	4.0%
O3(사후)	2017·2019	1,887	10.4%	0.706	**0.796**	53 → **73**	84 → **115**	45.5%	19.3%	4.6%

판정: 성공

모든 시점에서 ML이 충족률보다 더 많이 찾았다. 세 시점 합친 상위 20% 차이 +59명 [95%: +28 ~ +86명, 사람 단위 부트스트랩 1,000회]. 구간별 실제 부족률이 모든 시점에서 상위 10% > 10~30% > 나머지 순서. 가장 오래된 시점(O1, 학습 3,472행)은 차이가 작고(+4~11%), 학습 데이터가 쌓일수록 커진다.

15-2. 일 전환 정답 – 그만둠(T1) · 재취업(T2) (6개 패널, 봉인 시험)

D16 탐색에서 ML 이득이 가장 컸던 정답을 미래 차수 봉인 시험으로 확인했다. 비교: ① 계산기형(나이 + 지금 소득) ② 같은 입력 로지스틱 ③ LightGBM.

정답	패널	시험	발생률	계산기형	로지스틱	LightGBM	LGB − 계산기형 [하한]	LGB − 로지스틱	판정
T1 그만둠	한국복지패널	6,078	11.3%	0.575	0.686	**0.724**	+0.149 [+0.128]	+0.037	통과
T1 그만둠	한국노동패널	9,768	9.6%	0.635	0.701	**0.723**	+0.089 [+0.072]	+0.023	통과
T1 그만둠	재정패널	8,929	7.1%	0.711	0.758	**0.766**	+0.055 [+0.043]	+0.008	통과
T1 그만둠	한국의료패널	3,285	17.0%	0.633	0.687	**0.697**	+0.064 [+0.038]	+0.010	통과
T1 그만둠	고령화연구패널	2,505	17.6%	0.559	0.657	**0.657**	+0.098 [+0.061]	+0.001	통과
T1 그만둠	국민노후보장패널	1,085	11.4%	0.469	0.669	**0.682**	+0.213 [+0.142]	+0.013	통과
T2 재취업	한국복지패널	2,568	21.0%	0.573	0.746	**0.779**	+0.205 [+0.178]	+0.032	통과
T2 재취업	한국노동패널	4,800	15.2%	0.587	0.749	**0.769**	+0.181 [+0.157]	+0.020	통과
T2 재취업	재정패널	1,665	26.5%	0.631	0.698	**0.717**	+0.086 [+0.062]	+0.019	통과
T2 재취업	한국의료패널	4,094	9.8%	0.632	0.695	**0.688**	+0.057 [+0.024]	-0.006	통과
T2 재취업	고령화연구패널	2,410	10.0%	0.562	0.713	**0.723**	+0.161 [+0.114]	+0.009	통과
T2 재취업	국민노후보장패널	1,185	5.7%	0.515	0.673	**0.688**	+0.172 [+0.092]	+0.015	통과

판정: T1·T2 모두 성공 (6/6 조사 통과, 기준 80%)

계산기형 대비 결합: 그만둠 +0.104 [+0.068, +0.140], 재취업 +0.142 [+0.090, +0.195]. **같은 입력의 로지스틱 대비로도 LightGBM이 유의하게 높다**: 그만둠 +0.016 [+0.005, +0.027], 재취업 +0.016 [+0.006, +0.027]. 소득 하락에서는 차이가 없던 비선형 학습의 가치가 일 전환 문제에서는 드러난다. 재취업지원서비스에서 서비스 강도를 나누는 근거가 된다.

15-3. 확률 보정 개선 (E4) – 실패, 불채택

과제	A 원 확률	B 마지막 연도 Platt(기존)	C 교차 예측 Platt(신규)
노동(경상·재현)	2.76%p	2.05%p	2.98%p
복지(가처분)	3.23%p	2.69%p	3.13%p
국민노후(가처분)	1.50%p	4.56%p	1.90%p
국민노후(필요생활비)	2.72%p	3.50%p	1.72%p
재정(가처분)	3.13%p	2.82%p	2.96%p

ECE(낮을수록 좋음). C가 가장 좋은 과제는 1/5로 기준(4/5) 미달 → **불채택**. 어느 한 방식도 모든 패널에서 낫지 않았다. 확률 대신 **순위 구간과 판단 보류(16-3)**로 말하는 것이 지금 데이터로 정직한 방법이다.

16 머신러닝 확장 – ML만 할 수 있는 세 가지

앞 장들은 “ML이 계산보다 잘 맞힌다”를 보였다. 이 장은 **계산식으로는 원리상 할 수 없는 일**을 세 가지 실험으로 검증한다. 판정 규칙은 실행 전에 고정했다(prereg_MABC.txt).

16-1. 개인별 설명 – “왜 이 사람이 위험한가” (M-A, 성공)

> **TreeSHAP 기여도** – 한 사람의 예측 점수(로그 오즈)를 “기준값 + 변수별 기여”의 합으로 정확히 쪼개는 방법. 기여가 큰 변수가 그 사람의 위험 이유다.
> 예: 기준값 −2.5 + 지금 소득 +0.9 + 최근 4년 최저 소득 +0.6 + 연금 개시까지 거리 +0.3 … = 그 사람의 점수.

충실도 시험: 설명이 그럴듯하기만 한지, 모델이 실제로 그 변수에 기대는지 확인했다. 각 사람의 “위험을 올린 상위 3개 변수”를 학습셋 중앙값으로 바꿨을 때의 예측 변화를 무작위 3개를 바꿨을 때와 비교했다.

과제	시험 인원	상위 3개 제거 시 |변화|	무작위 3개	배수	p (윌콕슨)	AUC: 원래 → 상위 3개 제거
복지(가처분)	4,984	0.572	0.131	**4.4배**	<0.001	0.861 → 0.850
재정(가처분)	3,699	0.645	0.121	**5.3배**	<0.001	0.791 → 0.777
국민노후(가처분)	1,752	0.633	0.100	**6.3배**	<0.001	0.742 → 0.660
국민노후(필요생활비)	1,887	0.705	0.109	**6.5배**	<0.001	0.787 → 0.768
노동(경상·재현)	10,496	0.656	0.119	**5.5배**	<0.001	0.802 → 0.791

모든 과제에서 상위 3개를 지웠을 때 예측이 무작위보다 4.4~6.5배 크게 바뀌고, AUC도 크게 떨어진다. 설명이 모델의 실제 판단 근거라는 뜻이다. 대화형 진단의 “이유 3가지”를 이 값으로 만든다.

위험 상위 20%에서 가장 자주 1순위 이유가 된 변수

과제	1순위 이유 비율 (상위 4개)
복지(가처분)	현재 소득/빈곤선 81% · 최근 4년 최저 소득 12% · 1년 소득 변화 6% · 배우자 0%
재정(가처분)	현재 소득/빈곤선 63% · 최근 4년 최저 소득 24% · 1년 소득 변화 10% · 지역 1%
국민노후(가처분)	현재 소득/빈곤선 91% · 사적이전 비중 6% · 최근 4년 최저 소득 1% · 2년 소득 변화 1%
국민노후(필요생활비)	현재 소득/빈곤선 70% · 지금 소득/필요생활비 16% · 2년 소득 변화 8% · 사적이전 비중 4%
노동(경상·재현)	현재 소득/빈곤선 91% · 1년 소득 변화 4% · 연금 개시까지 거리 2% · 가구원 수 2%

16-2. 적응형 질문 – 사람마다 다른 질문 경로 (M-B, 실패)

고정 설문은 모두에게 같은 질문을 같은 순서로 묻는다. 적응형 질문은 지금까지의 답을 보고 **이 사람에게 가장 정보가 많은 다음 질문**을 모델이 고르고, 더 물어도 예측이 거의 바뀌지 않으면 멈춘다.

> **정보 가치** – 아직 묻지 않은 질문에 가능한 답 10개를 넣어 봤을 때 예측 확률이 얼마나 흔들리는지(표준편차). 많이 흔들릴수록 그 질문의 답이 판단을 바꾼다. 최대 정보 가치가 1%p 미만이면 멈춘다.

진단 모델은 일부 항목이 비어 있어도 예측하도록, 학습행을 무작위로 가려서 함께 학습했다. 같은 진단 모델로 고정 12문항(내부 검증 중요도 순)·전체 질문과 비교했다(시험셋 과제당 최대 1,500명).

과제	평가 인원	지금 소득만	고정 12문항	적응형	전체 질문	평균 질문 수	중앙값 / 90%	전체 질문 수
복지(가처분)	1,500	0.813	0.852	**0.857**	0.856	**7.4**	6 / 19	43
재정(가처분)	1,500	0.733	0.782	**0.784**	0.788	**10.8**	11 / 19	35
국민노후(가처분)	1,500	0.667	0.732	**0.714**	0.757	**10.1**	8 / 20	45
국민노후(필요생활비)	1,500	0.702	0.775	**0.764**	0.791	**8.8**	7 / 18	45
노동(경상·재현)	1,500	0.748	0.794	**0.789**	0.796	**10.7**	11 / 19	39

판정: 적응형이 고정 12문항보다 0.005 이상 떨어지지 않으면서 평균 질문 수가 12개 미만인 과제 2/5 → 실패(기준 4/5). 학습 데이터가 큰 복지·재정에서는 **더 적은 질문(평균 7.4·10.8개)으로 고정 12문항과 같거나 높았다**. 반면 국민노후(학습 6~7천 행)에서는 질문을 아낀 만큼 0.011~0.018 떨어졌고, 노동은 경계에서 미달(−0.005)했다. 정보 가치 추정이 작은 표본에서는 불안정하다는 뜻이다. 그래서 첫 제품의 진단은 **고정 12문항(ML이 고른 순서)**으로 하고, 적응형 질문은 진단 데이터가 쌓인 뒤 다시 검증하는 다음 단계로 둔다.

16-3. 판단 보류가 있는 예측 – “모르면 모른다고 말한다” (M-C, 성공)

> **conformal 예측** – 보정용 자료에서 “틀릴 확률이 α 이하가 되는” 점수 경계를 구해, 각 사람에게 {위험}, {안전}, {위험, 안전} 중 하나를 준다. 마지막은 판단 보류다. 확률 보정(E4)이 실패해도, 실제 하락자의 90%가 “위험”을 포함한 판정을 받도록 경계를 정할 수 있다.

과제	하락자 중 ‘위험’ 포함	비하락자 중 ‘안전’ 포함	위험 단독	안전 단독	판단 보류	위험 단독 중 실제 하락	안전 단독 중 실제 하락	기본 하락률
복지(가처분)	90.0%	91.9%	10.9%	62.8%	26.3%	**30.1%**	**1.0%**	6.0%
재정(가처분)	91.1%	91.4%	11.6%	41.4%	47.0%	**33.5%**	**2.2%**	10.3%
국민노후(가처분)	94.3%	90.7%	10.8%	18.8%	70.4%	**22.6%**	**3.0%**	9.9%
국민노후(필요생활비)	93.4%	91.7%	10.7%	24.3%	65.0%	**30.2%**	**2.8%**	10.4%
노동(경상·재현)	95.7%	87.1%	16.4%	33.3%	50.3%	**29.3%**	**1.3%**	9.9%

판정: 두 포함률이 모두 88% 이상인 과제 4/5 → **성공**(노동패널은 비하락자 포함률 87.1%로 미달). 학습기간과 시험기간이 달라도 보장이 거의 유지됐다. 현장 의미: “안전”으로 단독 판정된 사람의 실제 하락률은 1.0%~3.0%로 기본 하락률의 1/3~1/5다. 이 사람들은 2년 뒤 재점검으로 충분하고, 상담 자원은 “위험”(실제 하락 22.6%~33.5%)과 “판단 보류”에 쓴다. 판단 보류 비율이 패널마다 26~70%로 큰 것은 이 문제의 어려움을 그대로 드러낸 것이고, 그 사람들은 적응형 질문으로 더 묻는 대상이 된다.

16-4. 사각지대 – 지속 하락했는데 기초생활보장도 못 받을 사람 (M2, 지속 하락 모델로 충분)

지자체 사각지대 발굴에 그대로 쓰일 정답이다. 재정패널(기초생활보장 수급 유무)과 노동패널(기초생활보호 이전소득)로 "지속 하락 + 그 기간 수급 없음"을 만들고, 별도 모델이 필요한지 시험했다.

패널	시험	사각지대 비율	지속 하락자 중 미수급	지금 소득	지속 하락 모델(v3)	2단계(하락×미수급)	직접 학습	선택 모델 – v3 [하한]
재정패널	3,699	9.7%	**94.7%**	0.719	0.784	0.785	0.786	+0.002 [-0.002]
한국노동패널	10,496	9.4%	**95.2%**	0.747	0.794	0.794	0.794	+0.000 [-0.002]

판정: 지속 하락 모델로 충분

지속 하락으로 떨어진 사람의 **94.7%~95.2%가 4년 동안 기초생활보장을 한 번도 받지 않았다.** 그래서 사각지대 정답이 지속 하락 정답과 거의 같고, 별도 모델(2단계·직접 학습)은 지속 하락 모델보다 나아지지 않았다(차이 +0.000~+0.002, 0 포함). 이 결과는 사업적으로 오히려 강한 메시지다: **지속 하락 모델이 찾는 사람 대부분이 이미 사각지대 후보**이므로, 지자체용 별도 모듈 없이 같은 점수를 그대로 쓰면 된다.

16-5. 닮은 사람 – "나와 닮은 실제 30명은 어떻게 됐나" (M3, 성공 3/4)

> **가중 맨해튼 KNN** – 입력을 표준화하고 변수마다 중요도(내부 검증 순열 중요도)를 곱한 뒤, 차이의 절댓값 합이 가장 작은 학습셋 사람 30명을 찾는다. 그 30명 중 실제로 지속 하락한 비율이 "닮은 사람의 결과"다.

패널	시험	지금 소득	닮은 30명 비율	LightGBM	LightGBM과 순위 상관	판정
한국복지패널	4,984	0.811	**0.848**	0.861	0.84	통과
재정패널	3,699	0.724	**0.763**	0.791	0.84	통과
국민노후보장패널	1,752	0.668	**0.676**	0.742	0.70	미달
한국노동패널	10,496	0.751	**0.773**	0.802	0.81	통과

복지·재정·노동에서는 닮은 30명의 실제 결과만으로 지금 소득보다 0.02~0.04 높고, 최종 모델 점수와 순위 상관이 0.81~0.84다. 즉 숫자 기여도(16-1)와 함께 **"당신과 비슷한 30명 중 X명이 실제로 부족해졌다"**는 사례형 설명을 붙일 수 있다. 국민노후패널은 표본이 작아 기준(+0.02)에 못 미쳐 이 패널에서는 쓰지 않는다. 개인 기록은 보여주지 않고 30명 집계만 보여준다.

16-6. 가장 작은 변화 – “무엇을 바꾸면 위험 구간에서 벗어나나” (M7, 방향 일치 확인)

> **제약 반사실 탐색** – 바꿀 수 있는 항목(취업, 연금 가입, 금융자산)만 현실적인 범위에서 바꿔 보며, 위험 상위 20% 경계 아래로 내려가는 가장 작은 변화를 찾는다. 나이·성별·학력·소득 이력은 바꾸지 않는다.

패널	위험 상위 20% 인원	시도한 행동	1개로 벗어남	2개 이내로 벗어남	모델이 말하는 취업 효과	실제 관측(재취업자 − 미취업 유지자)
한국복지패널	591	취업 · 개인연금 가입 · 자산+1천만 · 자산+3천만	3.0%	**3.7%**	-0.4%p	-3.1%p
재정패널	463	취업 · 공적연금 가입 · 자산+1천만 · 자산+3천만	15.8%	**17.9%**	-0.9%p	+0.4%p
국민노후보장패널	256	취업 · 공적연금 가입 · 자산+1천만 · 자산+3천만	6.2%	**7.8%**	-0.6%p	-4.0%p
한국노동패널	2,024	취업 · 공적연금 가입 · 자산+1천만 · 자산+3천만	9.7%	**11.0%**	-1.3%p	-6.0%p

가장 흔한 최소 변화

패널	최소 변화 (위험 상위 20% 중 비율)
한국복지패널	취업 1.0% · 개인연금 가입 1.0% · 금융자산 +3,000만원 0.5% · 금융자산 +1,000만원 0.5%
재정패널	금융자산 +1,000만원 7.8% · 금융자산 +3,000만원 5.2% · 공적연금 가입 1.5% · 취업 1.3%
국민노후보장패널	취업 3.9% · 금융자산 +1,000만원 1.2% · 공적연금 가입 1.2% · 취업 + 금융자산 +1,000만원 0.8%
한국노동패널	취업 5.5% · 금융자산 +1,000만원 2.3% · 공적연금 가입 1.3% · 취업 + 금융자산 +1,000만원 0.7%

방향 검증: 방향 일치 확인

t 시점 미취업자 26,914명을 모델 위험 10분위로 나눠 같은 위험끼리 비교하면, 2년 안에 재취업한 사람의 실제 지속 하락률이 계속 미취업인 사람보다 **-4.3%p** 낮았다(95% -5.6 ~ -3.2%p, 사람 단위 부트스트랩). 모델이 말하는 방향(취업 → 위험 감소)과 같다. 재정패널만 차이가 없었다(+0.4%p).

정직한 해석: 위험 상위 20% 가운데 행동 1~2개로 경계를 벗어나는 사람은 **4%~18%**뿐이다. 위험의 대부분은 바꿀 수 없는 소득 이력(최근 4년 최저 소득, 변동성)에서 온다. 그래서 서비스의 “채우기 계획”은 개인 행동보다 **제도 연결(기초연금·주택연금·재취업지원)을 먼저** 제시하고, 반사실 결과는 “이런 변화가 있었던 사람들은 위험이 낮았다”는 예측으로만 표시한다(효과 보장 아님). 모델이 말하는 취업 효과(−0.4~−1.3%p)가 실제 관측 차이(−4.3%p)보다 작은 것도, 재취업 자체가 다른 좋은 조건과 함께 오기 때문으로 보이며, 인과로 말하지 않는 원칙과 맞다.

16-7 머신러닝이 얼마나 업그레이드됐나

처음 보고서(v1)에서 지금까지 ML이 보여주는 것이 어떻게 달라졌는지 다섯 단계로 정리했다.

단계	무엇을 보여주나	처음 (v1)	지금
1. 예측력	기준보다 잘 맞히나	지금 소득 대비 +0.031	반복 관측 정답으로 **+0.064**, 복지 0.870. 일 전환 계산기형 대비 +0.104·+0.142
2. 검증의 엄격함	우연·누수·과적합이 아닌가	봉인 시험, 메타분석, 셔플, 학습곡선	+ 사람 단위 부트스트랩, 처음 보는 사람(+0.065), 집단 11개, 롤링 3시점(E1b), 이식·재보정
3. 모델 선택의 근거	언제 비선형 학습이 필요한가	사전 지정 HGB가 로지스틱보다 낮음	소득 하락: 차이 없음(근거와 함께). **일 전환: LightGBM이 로지스틱보다 유의하게 높음** (+0.016)
4. 신뢰할 수 있는 출력	왜 그런 판단인가, 모르면?	전체 중요도·부분의존, 확률 어긋남	**개인별 이유**(충실도 4.4~6.5배), **닮은 30명 사례**(3/4 통과), **판단 보류**(“안전” 중 하락 1.0%~3.0%)
5. 의사결정 지원	무엇을 물을지, 무엇을 바꿀지	없음	질문 수 고정(ML 선택 > 전문가) 성공 · 적응형 질문 실패 · **가장 작은 변화** 방향 일치 확인(바꿀 수 있는 사람은 소수라는 것도 확인) · 사각지대는 같은 모델로 충분

한 줄 요약

처음에는 “계산보다 AUC가 조금 높은 예측기”였다. 지금은 **사람별로 이유를 말하고(숫자·사례), 모르면 판단을 보류하고, 무엇을 바꾸면 되는지와 그 한계까지 말하는 검증된 모델**이다. 남은 과제는 인과 추론(반사실은 효과가 아님), 운영 중 성능 모니터링 기록, 집단별 오탐·미탐 차이 같은 공정성 지표다.

17 실패 기록 (참고)

결과가 좋지 않았거나 계획대로 되지 않은 것을 모두 모았다. 판정에서 지운 것은 없다.

#	무엇	무슨 일이 있었나	어떻게 처리했나
1	정답 v1 (2년 뒤 1회 하락)	빈곤선 근처의 한 해 출렁임이 정답에 섞여 잡음이 컸다. ML 이득 +0.046에 그침	반복 관측 정답(3번 중 2번)으로 교체 → 이득 +0.069
2	상태형 정답 (M1 방식)	AUC 0.907로 높았지만 지금 소득만으로 0.888. 기존 서비스와 같은 질문	비교용으로만 남김
3	AUC 0.85 목표	복지패널(0.870)만 달성. 재정·국민노후 0.75~0.80. 패널 통합·앙상블로도 거의 안 오름	현장 지표(같은 인원 발견 수)로 말함
4	v1 사전 지정 HGB	같은 입력의 로지스틱보다 0.010 낮았다(설정 문제)	v3는 LightGBM으로 사전 지정, 원인 공개
5	소득 하락에서 부스팅 ≈ 로지스틱	LightGBM − 로지스틱 -0.002 (0 포함)	일 전환 문제에서 부스팅 우위 확인 (15-2), 최종 모델은 두 모델 앙상블
6	E1 설계 실수	위험 구간 경계를 계산 가능자 전체로 정해 계산상 괜찮은 집단의 “높음”이 10명뿐	E1b로 보완, 처음 채점한 두 시점으로 판정(성공)
7	E4 확률 보정 개선	새 방식이 5개 중 1개에서만 최선 → 불채택. 국민노후패널은 기존 재보정이 오히려 악화(1.5 → 4.6%p)	확률 대신 순위 구간 + 판단 보류(16-3)로 말함
8	M-C 노동패널	비하락자 포함률 87.1%로 기준(88%) 미달	4/5 통과로 판정은 성공, 미달 공개
9	이식 − 국민노후	다른 패널에서 학습한 공통 입력 모델은 국민노후에서 0.68~0.73	국민노후는 자체 추가 입력과 함께 사용
10	패널 합쳐 학습	합쳐도 이득 없음(D16과 같은 결론)	패널별 학습 + 결합 메타분석 유지
11	M-B 적응형 질문	5개 중 2개 과제에서만 통과(기준 4/5). 국민노후에서 0.011~0.018 하락	첫 제품은 고정 12문항, 적응형은 다음 단계
12	M2 사각지대 별도 모듈	2단계·직접 학습 모두 지속 하락 모델보다 나아지지 않음 (+0.000~0.002)	지속 하락자의 95%가 미수급 → 같은 점수를 사각지대 발굴에 그대로 사용
13	M3 국민노후	닮은 30명 비율이 지금 소득보다 +0.008(기준 +0.02 미달)	국민노후에서는 사례형 설명을 쓰지 않음
14	M7 바꿀 수 있는 위험	위험 상위 20% 중 행동 1~2개로 벗어나는 사람은 4~18%뿐. 재정패널은 재취업 방향 차이 없음	채우기 계획은 제도 연결을 먼저, 반사실은 예측으로만 표시
15	실행 중 오류	패키지 저장소 차단(이후 해제), HistGB 빈 열 오류, 부분의존 문법 변경, 첫 부분의존 그림의 잘못된 해석 제목	모두 수정 후 전체 재실행, 그림 제목은 데이터 모양대로 다시 붙임

18 판정 요약 · 한계 · 부록

구분	내용	결과
판정	가처분 3개 패널, 최종 모델 – 지금 소득, DeLong → 랜덤효과. 하한 > 0, 실질 +0.03, 3/3 양수	+0.064 [+0.053, +0.075] **통과**
판정(사전 지정 모델)	LightGBM 단독 – 지금 소득	+0.060 [+0.045, +0.075] **통과**
재현 · 이식	노동(경상) · 의료 · 고령화 (경상)	+0.056 · +0.032 · +0.017 (모두 양수)
탐색	모델 비교, 질문 수 고정, 부트스트랩, 집단별, 처음 보는 사람, 보정·이식	보조 근거, 판정에 쓰지 않음
추가 판정 (D16 검토 후)	E1b 2차 검진 · E2 그만둠·재취업 · E4 보정 개선 · M-A 개인별 설명 · M-B 적응형 질문 · M-C 판단 보류 · M2 사각지대 · M3 닮은 사람 · M7 가장 작은 변화	E1b **성공** · E2 **성공 6/6 ×2** · E4 **불채택** · M-A **성공** · M-B **실패** · M-C **성공 4/5** · M2 같은 모델로 충분 · M3 **성공 3/4** · M7 **방향 일치**
공개할 실패	• **AUC 0.85는 복지패널에서만** 넘었다. 재정·국민노후는 학습 표본이 작고(6~9천 행) 소득 측정 정밀도가 낮아 0.75~0.80. 패널 통합 학습·앙상블로도 거의 안 올랐다. • **정답 정의를 네 번 바꿨다.** 처음 설계(2년 뒤 1회 하락)는 잡음이 커서 이득이 작았다. 바꾼 이유와 모든 버전의 결과를 3장에 공개했다. • **부스팅이 로지스틱보다 확실히 낫지 않다**(부트스트랩 구간이 0 포함). 이득의 주원천은 정보 설계다. • 최종 앙상블은 v3 탐색 중에 정했다. 사전 지정 LightGBM 결과를 함께 보고한다. • 원 확률은 패널마다 어긋나고, 국민노후패널에서는 작은 표본으로 한 재보정이 오히려 나빴다.	신뢰를 위해 그대로 보고

한계

- **4년 관측 조건**: 정답이 t+4를 요구해 시험셋이 2016~2021년 기준 차수다. 최근 경기(2022년 이후)는 시험에 덜 반영됐다.
- **표본 크기**: 국민노후패널 시험 1,752~1,887행. 개별 신뢰구간이 넓어 결합 분석으로 보완했다.
- **인과 아님**: 중요도·부분의존은 예측에 쓰인 패턴이다. 처방 효과는 파일럿에서 별도로 검증해야 한다.
- **가중치**: 성능은 표본(비가중) 기준. 전국 비율을 말할 때는 패널 가중치를 적용해야 한다.

A 부록 – 재현 정보

단계	스크립트 · 내용
패널별 변환	`b_koweps · b_nastab · b_kreis · b_klips · b_khp · b_klosa` → 공통 스키마
이력 변수·결과 연결	`build_common.py` – CPI, 균등화, 경상 빈곤선, t–4~t+4 연결
정답 v3	`label_v3.py` – 가처분 빈곤선, 필요 생활비 기준선, 3번 중 2번 정답, 시험 봉인
전체 분석	`v3_full.py` – 모델 비교, DeLong·메타, 부트스트랩, 질문 수 고정, 학습곡선·셔플, 중요도·부분의존, 집단별, 처음 보는 사람, 보정·이식, 사업 지표
그림·보고서	`figs_v3.py · report_v3.py`
환경	Python 3.13 · scikit-learn 1.9.1 · LightGBM 4.7.0 · XGBoost 3.4.1 · CatBoost 1.2.10 · pandas 3.0 · 시드 42